# 视网膜多病种筛查中的单调质量路由与共享多标签头

**一项基于 RFMiD 真实像素的六组对照评价**

方法学论文

# 目 录


摘要 ..... 4

1 引言 ..... 5

1.1 研究背景与具体问题 ..... 5

1.2 已有工作的进展与三处未决问题 ..... 6

1.3 本文目标与贡献 ..... 7

2 相关工作 ..... 7

2.1 视网膜基础模型与多病种筛查 ..... 7

2.2 图像质量评估与质量加权融合 ..... 8

2.3 部分标签与多标签学习 ..... 8

2.4 概率校准与决策曲线 ..... 8

3 材料与方法 ..... 9

3.1 数据与队列 ..... 9

3.2 特征提取与骨干替代 ..... 9

3.3 软质量向量 ..... 10

3.4 单调有界质量路由 ..... 10

3.5 掩码二元交叉熵损失 ..... 11

3.6 质量条件骨干路由 ..... 11

3.7 实验臂与训练设置 ..... 12

3.8 评价指标、校准与工作点 ..... 14

3.9 统计推断 ..... 15

3.10 软件与复现 ..... 15

4 结果 ..... 15

4.1 队列、质量分布与信息流 ..... 15

4.2 主结果 ..... 17

4.3 配对比较与终点稳健性 ..... 18
4.4 分终点判别 ..... 21
4.5 校准代价 ..... 22
4.6 校准误差的来源 ..... 25
4.7 事后校正阶梯 ..... 26
4.8 工作点与阈值搬移 ..... 28
4.9 临床效用 ..... 31
4.10 决策曲线 ..... 31
4.11 质量分层 ..... 32
4.12 路由器的实际取值与推理期干预 ..... 33
5 讨论 ..... 36
5.1 主要发现 ..... 36
5.2 与已有工作的关系 ..... 37
5.3 校准误差为什么表现为 logit 偏移 ..... 38
5.4 阈值搬移的两种读法 ..... 38
5.5 质量分层的解释边界 ..... 39
5.6 局限 ..... 39
5.7 实践含义 ..... 40
6 结论 ..... 41
7 数据与代码可用性 ..... 42
参考文献 ..... 43

## 摘要

**背景。** 彩色眼底照相是社区眼保健中获取成本最低的影像检查之一。以 Reti-Pioneer 为代表的多病种筛查框架把若干冻结的视觉基础模型组合起来，并在融合阶段引入图像质量信息。公开实现把好、可用、差三类图像的质量权重固定为 1、0.5 与 0，并按病种逐个拟合二分类头。

**问题。** 这套骨架里至少有三处部件可以替换而无需重训骨干。质量权重能否改成受约束的可学习量。多个病种能否由一个共享多标签头同时输出。图像质量能否直接决定集成中各骨干的混合比例。三处改动各自带来什么，此前缺少在同一数据、同一评价协议下的对照。

**方法。** 本文在 RFMiD 的 3200 张真实眼底像素上冻结编码器，训练六组实验臂。三个骨干槽位由 ImageNet 预训练的 Swin Transformer V2-B、ViT-B/16 与 ViT-S/16 填充。E0 是固定权重单任务基线。E1 换成单调有界质量路由。E2 用掩码二元交叉熵训练八个共享头。E3 同时启用单调路由与掩码多任务。E4 用无约束自由线性路由替换单调路由。E5 在 E3 之上加入质量条件骨干路由。报告轮次按验证集宏平均 AUROC 选择。工作点阈值在验证集上确定后冻结。全部区间为图像层级自助法，重采样 1000 次。

**结果。** 测试集 640 张。E0 的宏平均 AUROC 为 0.932，E1 为 0.934，配对差值为 +0.001，区间 −0.017 至 +0.020。E2 为 0.896，E3 为 0.906，配对差值 +0.010，区间 −0.001 至 +0.021。E4 为 0.898，相对 E3 为 −0.008，区间上限 +0.003。E5 为 0.916，相对 E3 为 +0.010，区间下限 +0.00005。三组多任务比较在逐一剔除任一终点后符号均不改变。多任务臂的平均分病种期望校准误差为 0.122 至 0.149，单任务臂为 0.024 至 0.031。温度缩放没有降低这一误差，六个臂缩放后全部上升。把每个终点的 logit 加上验证集患病率的 logit，一个自由参数都不用，多任务臂的误差从 0.149 降到 0.036，从 0.122 降到 0.039。共享头的 logit 中心与终点 logit 流行率的相关系数为 0.813 至 0.864，斜率接近 1，误差的来源是位置偏移，尺度错配解释不了这一大小。推理期把路由器权重强制改回固定值，六个臂的 AUROC 变化不超过 $3.1\times10^{-5}$，单图概率变化不超过 0.036，路由增益的来源落在训练轨迹上，质量权重的重新分配贡献很有限。按 95% 特异度冻结阈值评价，E5 的糖尿病视网膜病变灵敏度为 0.540，E0

为 0.661，配对差值 −0.121，区间 −0.192 至 −0.050。若允许在测试集上事后挑阈值，E5 达到 0.766，落差 0.226，为六个臂之最。

**结论。** 在公开多病眼底数据上，掩码多任务配合单调质量路由带来方向一致的宏平均增益，幅度约 0.010，区间下限贴近零。单调约束的去留会改变结果，去掉后性能下降。共享头的校准代价不是锐度问题，单一的标量温度无法修正，而按终点对齐 logit 位置几乎可以消掉它。质量条件骨干路由提高了判别与 Brier 分数，同时让高特异度工作点上的阈值搬移最不稳定。上述结论限于 RFMiD 标签体系、ImageNet 替代骨干与单一种子。

**关键词。** 彩色眼底照相，多病种筛查，图像质量，单调路由，部分标签学习，概率校准，决策曲线分析

# 1 引言

## 1.1 研究背景与具体问题

糖尿病视网膜病变、青光眼与年龄相关性黄斑变性在早期通常没有自觉症状。彩色眼底照相能在基层完成采集，单次拍摄成本低，通量高，因此长期被当作机会性筛查的入口。过去十年，基于卷积网络与 Transformer 的自动判读在单病种任务上已经接近专家判读的下限。真实筛查场景里仍然有两类限制。

第一类是图像质量。散瞳不充分、屈光介质混浊、曝光偏差与镜头污渍都会削弱可见结构。同一台相机在同一批次里也可能同时产出清晰与模糊的图像。第二类是病种覆盖。一次拍照往往能回答多个问题，而单输出模型只回答一个。基层的实际需求是同一次采集给出若干病种的提示。

大规模视网膜预训练为第二类问题提供了可行路径。RETFound 在 160 万张眼底图像上做掩码自编码预训练，随后在多个下游任务上以少量标注微调即可获得较强迁移能力[1]。Reti-Pioneer 走了另一条路线。它把三个互补的冻结骨干组合成集成，分别是 Swin Transformer、Vision Mamba 与 RETFound，并在融合阶段引入图像质量与结构化元数据[2]。该系统在 107 730 张眼底图像上开发，对六种内分泌与代谢疾病的内部测试 AUROC 介于 0.699 与 0.833 之间，外部验证覆盖中国多家医院与新加坡多种族队列。

Reti-Pioneer 的一项消融值得单独提出。开发团队报告，加入质量感知模块后，2 型糖尿病的 AUROC 相比只用高质量图像训练、以及相比在全部质量图像上训练但不加质量模块，都有提升[2]。这说明质量信息在融合阶段仍然有用，预处理阶段一次性丢弃会损失可用信息。该结果同时提示一个可以继续追问的工程问题。质量以什么形式进入融合，是一个可以独立设计、独立检验的部件。

### 1.2 已有工作的进展与三处未决问题

把 Reti-Pioneer 的论文与其公开实现并读，可以看到三处可以单独检验的问题[2]。三处都不涉及重训基础模型，因此在公开数据上就能验证。

第一处是质量权重的可学习性。公开代码把好、可用、差三类权重写死为 1、0.5 与 0，训练中冻结[3]。固定权重简单可靠，代价是无法适应不同采集设备的质量分布。把权重放开为可学习参数，最直接的写法是一个三输入到一输出的线性映射。这种写法没有顺序约束，训练中完全可能出现差质量权重高于好质量的解。一旦出现，模型会给劣质图像更高的融合权重，与临床常识相反。可行的折中是保留可学习性，同时把质量层级的顺序写成硬约束，并检验这一约束是否真的带来差异。

第二处是头的组织方式。论文叙述强调多任务筛查，公开训练脚本却按病种循环，每次拟合一个二分类头。这在标签完备的队列上可行，在多标签公开数据集上则浪费了标签之间的共现信息。RFMiD 对同一张图像标注多种体征，糖尿病视网膜病变常与玻璃膜疣同时出现。共享头可以让这些共现模式进入同一组参数。公开数据集还有另一类复杂情况，不同队列的标签词表只部分重叠，某些终点在部分样本上从未被观察。把未观察项当作阴性，监督信号会被系统性污染。

第三处是集成权重的分配依据。Reti-Pioneer 以加权软投票聚合三个骨干的预测，权重由 logit 的 softmax 温度决定，与图像质量无关。不同骨干对劣质采集的敏感度并不相同。Swin 依赖局部窗口，ViT 依赖全局注意力，二者在模糊图像上的失效模式不同。让质量分布直接决定骨干权重是一个自然的假设，但需要实验检验它是否真的带来增益，以及代价落在哪里。

### 1.3 本文目标与贡献

本文以 RFMiD 为实验床，在同一冻结骨架上改动上述三处部件，给出可复现的对照评价。研究问题可以写成一句话。当冻结骨架固定时，质量路由的约束形式、头的共享方式与骨干权重的分配依据，是否改变判别、校准与决策行为。

我们做五件事。设计并实现单调有界质量路由器，用 softplus 与累积归一化保证三类权重非降且好质量为 1。用掩码二元交叉熵训练八个共享头，未观察标签不进入损失。实现质量条件骨干路由，把三类质量概率映射为三个骨干上的 softmax 混合。建立一套评价协议，包括按验证集选轮次、互斥校准、图像层级自助法、DeLong 区间、分病种校准误差、冻结工作点与决策曲线。在报告工作点时同时给出可部署口径与事后上界，使阈值搬移的代价可见。

贡献有四点。第一，把三处部件放在同一数据与同一协议下比较，并如实报告哪些差异能与零区分、哪些不能。第二，用逐一剔除单一终点的做法检验宏平均差值的稳健性，避免一个强终点撑起整个结论。第三，用推理期强制改写路由器参数的办法分离路由增益的来源，结论是增益不来自质量权重的重新分配。第四，指出共享头的校准误差表现为 logit 位置偏移，并给出一条只需读取验证集患病率的零参数校正，它在多任务臂上把误差降低约四分之三。

## 2 相关工作

### 2.1 视网膜基础模型与多病种筛查

视网膜图像的自监督预训练在过去三年进展明显。RETFound 采用掩码自编码目标，在无标注眼底图像上学习通用表征，随后在眼科与全身性疾病任务上验证迁移能力[1]。其价值在于把标注需求从十万量级降到千量级。Reti-Pioneer 走了集成路线，把若干已有基础模型当作专家，通过组合获得互补性[2]。该系统的报告显示，集成增益在外部队列上比在内部测试上更稳定。异构模型集成在眼底多病种任务上的可行性此前也有报道[4]。

多病种筛查的临床价值已被反复讨论。眼是全身边微血管与神经组织的可直视窗口，视网膜特征与糖尿病、高血压、血脂异常之间存在流行病学关联。一项法国人群队列的系统评估指出，单中心 AUROC 在相机型号与标签体系漂移时容易高估可迁移

性[5]。这一提醒对本文同样适用，因此本文把结论严格限制在 RFMiD 的标签体系内。

### 2.2 图像质量评估与质量加权融合

EyeQ 把眼底图像质量分为好、可用与拒收三类，并提供了带专家标注的公开数据[6]。后续工作把分类骨干从卷积网络换成 Transformer，同时融合 RGB、HSV 与 CIELAB 三个色彩空间。三类别的 ROC 在 EyeQ 上分别做到 0.96、0.81 与 0.96[7]。一项在 2434 张图像上的研究进一步区分了病变相关的劣质与伪影相关的劣质，说明差质量本身并不是一个同质类别[8]。这些工作解决的是质量判读本身。

质量判读之后如何使用，是另一个问题。常见做法是加权融合，把质量概率转成一个标量权重，再与图像特征做双线性交互。Reti-Pioneer 使用的正是这一形式。其局限在于权重与质量层级的关系没有被约束，训练中可能出现顺序颠倒。本文的单调路由器针对这一点，属于对融合权重的小幅有约束改进，并不改写质量分类体系。

### 2.3 部分标签与多标签学习

RFMiD 提供 3200 张图像的 45 类体征标注，官方划分为训练 1920 张、验证 640 张、测试 640 张[9]。BRSET 提供 16 424 张巴西人群眼底图像与 13 类标签[10]。ODIR-5K 提供 5000 张双侧图像与 8 类眼病标注[11]。三个数据集都可以直接下载，标签词表互不相同。

多个队列联合训练时，掩码监督是标准做法。把未观察标签标记为缺失，只让已观察项进入损失分母。这一做法在医学影像分割与多中心分类中都有先例。本文把它用到眼底多病种场景，并检验它与质量路由的交互。需要提前说明一点。RFMiD 的八个终点在全部样本上都有标注，因此掩码在本次数据上不改变损失数值，它的作用体现在跨队列兼容性与协议定义上。

### 2.4 概率校准与决策曲线

校准的前期工作给出了本文依赖的三块基础。现代深度网络的置信度常与准确率脱节，温度缩放是一种简洁有效的事后校正[12]。综述工作把校准拆成位置、斜率与整体分布三个维度，并提醒单一的校准误差指标会把不同来源的问题混在一起[13]。贝叶斯分箱给出了非参数的替代方案[14]。Platt 的 sigmoid 标定与分类型标定构成另外两类

常见做法[15,16]。决策曲线分析把净收益写成阈值概率的函数，使模型与全部治疗、全部不治疗两种策略可以直接比较[17]。在社区筛查场景中，一项基于决策曲线的真实世界研究讨论了微调 RETFound 的实际效用，发现净收益优势主要集中在中等风险区间[18]。

本文把校准与决策曲线当作报告惯例，没有当作方法创新。报告口径参照预测模型报告的通行规范[19]。这样做的一个直接后果是必须接受它们暴露的问题。后文会看到，多任务共享头的校准明显差于单任务头，而且这一差距的性质与通常的过度自信不同。

## 3 材料与方法

### 3.1 数据与队列

实验使用 RFMiD 的官方划分。训练集 1920 张，验证集 640 张，测试集 640 张，合计 3200 张。每张图像对应一次眼底采集。本文保留患病率足以支撑稳定估计的八个终点，分别是任意病变、糖尿病视网膜病变、屈光介质混浊、视盘杯盘比异常、豹纹状眼底、玻璃膜疣、年龄相关性黄斑变性与近视性改变。

有一处容易误解的地方需要说明。RFMiD 的图像编号在不同子集内各自从 1 开始，训练集、验证集与测试集之间存在编号值的重合。这不表示同一患者跨子集重复，因为每个编号在各自子集内只对应一张图像。正因如此，本文自助法重采样的单位是图像，区间解释为图像层级的抽样不确定性。

测试集的终点患病率如下。前四项偏高，任意病变 0.791，糖尿病视网膜病变 0.194，屈光介质混浊 0.162，视盘杯盘比异常 0.142。后四项偏低，豹纹状眼底 0.083，玻璃膜疣 0.072，年龄相关性黄斑变性 0.048，近视性改变 0.050。低患病率终点的平均精度天然受限，其阳性样本在 640 张中只有 31 至 53 例，这一点决定了后文对平均精度的解读必须保守。

### 3.2 特征提取与骨干替代

本文冻结编码器，在预提取特征上训练融合与分类头。三个骨干槽位按 Reti-Pioneer 的规模设定，Swin 槽为 1024 维，RETFound 槽为 1024 维，Vision Mamba 槽为 384 维。

实际使用的权重与原始系统不同，原因需要交代。RETFound 的公开权重需要申请访问，起草环境无法获得。Vision Mamba 依赖的 CUDA 算子在本机不可用。因此三个槽位分别由 ImageNet 预训练的 Swin Transformer V2-B、投影到 1024 维的 ViT-B/16 与 384 维的 ViT-S/16 填充。特征来自 RFMiD 的真实眼底像素，逐张前向提取后缓存，不由标签派生。

这一替代的后果是绝对性能不可与 Reti-Pioneer 的报道直接比较。本文所有 AUROC 应读作同一骨架下的相对基准，用于比较不同部件的表现。特征出处记录在仓库的 `data/rfmid/FEATURE_PROVENANCE.json` 中，写明每个槽位的实际权重来源与替代理由。

### 3.3 软质量向量

本文没有训练独立的 EyeQ 风格质量分类器，改为从像素直接计算两个代理量。第一个是梯度能量，由相邻像素差的方差给出，反映图像锐度。第二个是灰度均值的曝光响应，用高斯核把偏离中值的亮度映射到 0 至 1，反映曝光过度与不足。两个量按 0.65 与 0.35 加权成一个综合分数，再经分段线性映射得到好、可用、差三类概率，最后做归一化。

这一设计是本文的一处明确妥协。代理量与专家判读的一致性没有经过系统验证，因此质量分层的结果只能用于机制核查，不能用于临床质量控制的结论。第 4.11 节会显示这一限制的实际影响。

测试集的软质量分布如下。按三类概率的最大值归档，好 9 张，可用 546 张，差 85 张。三类概率分量的均值分别为 0.077、0.740 与 0.183。好质量样本过少，无法支撑稳定的分层估计，后文对此单独说明。

### 3.4 单调有界质量路由

设质量概率向量为 $q=(q_{good},q_{usable},q_{bad})$，三个分量非负且和为 1。固定路由使用常数权重 $w=(1,0.5,0)$，融合标量为 $s=q^{\top}w$。这是公开实现的基线。

自由线性路由把标量写成 $s=a^{\top}q+b$，其中 $a\in\mathbb{R}^3$ 与 $b$ 均可学习。它没有任何顺序约束。

单调路由引入可学习增量 $\delta\in\mathbb{R}^3$，按式 (1)、式 (2) 与式 (3) 构造权重。

$$u_i = \mathrm{softplus}(\delta_i) + \varepsilon, \quad i = 1, 2, 3 \tag{1}$$

$$c_i = \sum_{j=1}^{i} u_j \tag{2}$$

$$w_i = \frac{c_i}{c_3} \tag{3}$$

其中 $\varepsilon=10^{-6}$ 用于避免除零。由于 softplus 严格为正，累积和严格递增，因此 $0<w_1<w_2<w_3=1$。按差、可用、好的顺序对齐后，差质量权重最小，好质量权重恒为 1。初始化取 δ 使 $w$ 接近 $(10^{-4},0.5,1)$，与固定基线相差很小，训练可以平稳起步。

这个设计的代价是表达能力受限。三个权重只剩两个自由度，因为归一化固定了最大值。换来的是任何训练轨迹都不会出现顺序颠倒。第 4.12 节用自由线性路由作为对照，并用推理期强制改写参数的办法直接检验这一约束的因果作用。

### 3.5 掩码二元交叉熵损失

共享头输出 $K$ 个 logit。对第 $k$ 个终点，若样本的标签 $y_k$ 已观察，则计入损失。若为缺失，则不计入。损失写成式 (4)。

$$\mathcal{L} = -\frac{1}{\sum_{k=1}^{K} m_k} \sum_{k=1}^{K} m_k [y_k \log \sigma(z_k) + (1 - y_k) \log(1 - \sigma(z_k))] \tag{4}$$

其中 $m_k \in \{0,1\}$ 是观察指示，σ 是 sigmoid，$z_k$ 是第 $k$ 个 logit。分母取观察指示之和，缺失多的样本不会被系统性降权。

本文的 RFMiD 子集八个终点在所有样本上都有标注，因此掩码在本次实验中不改变损失数值。它保留在代码里，作用是让同一套训练流程可以直接接上标签词表不完整的队列。这一设计在只有单一队列时无法通过实验体现，第 5.6 节把它列为局限。

### 3.6 质量条件骨干路由

启用后，一个两层感知机把质量向量映射为三个骨干上的 softmax 权重，按式 (5) 计算最终 logit。

$$z=\sum_{h=1}^{3}\alpha_h(q)\,z^{(h)},\quad \alpha(q)=\mathrm{softmax}(W_2\,\mathrm{SELU}(W_1 q+b_1)+b_2) \tag{5}$$

其中 $z^{(h)}$ 是第 $h$ 个骨干头的 logit。E5 在单调路由与掩码多任务之上启用该模块。它与单调路由作用于不同层级。单调路由调整单骨干内部的质量融合标量，骨干路由调整骨干之间的混合比例。两者的参数互不共享。

### 3.7 实验臂与训练设置

六个实验臂的配置如表 1。E0 与 E1 是单任务臂，只训练糖尿病视网膜病变一个头，用于与公开代码基线对齐。E2 至 E5 是八头共享臂。

**表 1** 实验臂配置。除标注的差异外，其余训练条件相同。

| 实验臂 | 质量路由 | 头结构 | 骨干路由 | 检验的问题 |
|---|---|---|---|---|
| E0 | 固定 1/0.5/0 | 单头 | 无 | 公开代码基线 |
| E1 | 单调有界 | 单头 | 无 | 单任务下的路由增益 |
| E2 | 固定 1/0.5/0 | 八头共享，掩码损失 | 无 | 多任务本身的影响 |
| E3 | 单调有界 | 八头共享，掩码损失 | 无 | 两部件组合 |
| E4 | 自由线性 | 八头共享，掩码损失 | 无 | 单调约束是否必要 |
| E5 | 单调有界 | 八头共享，掩码损失 | 质量条件 softmax | 骨干层级再分配 |

训练设置为学习率 $1\times10^{-4}$，权重衰减 0.01，批大小 64，骨干冻结。E0 至 E3 与 E5 训练 15 个轮次，E4 因新增路由参数训练 23 个轮次。类别不平衡用正样本权重处理。随机种子固定为 42。方法信息流见图 1。

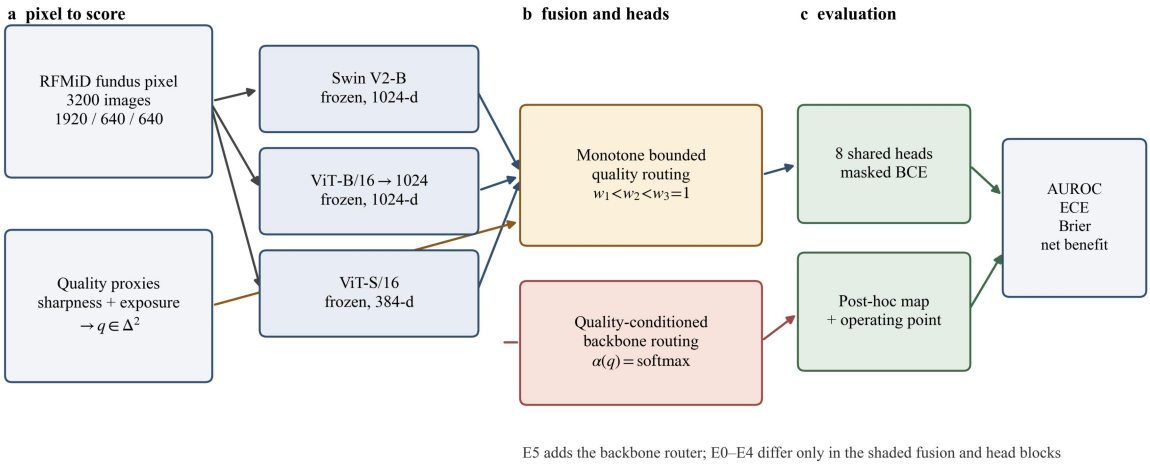



**图 1** 方法信息流。左侧为三个冻结骨干的特征，中部为单调质量融合与共享多标签头，右侧为校准与决策曲线评价。橙色部分为 E5 新增的质量条件骨干路由。

报告轮次按验证集宏平均 AUROC 选择，六个臂的选择结果见表 2。这一改动使报告的性能与实际做过的模型选择一致。早期流程按文件名字符串排序取检查点，结果 9.*pt* 排在 15.*pt* 之后，六个臂实际都报告了第 9 轮，与训练日志不符。

**表 2** 报告轮次的选择。验证集宏平均 AUROC 为唯一选择依据。

| 实验臂 | 训练轮次 | 选中轮次 | 该轮验证宏平均 AUROC |
|---|---|---|---|
| E0 | 15 | 12 | 0.944 |
| E1 | 15 | 14 | 0.922 |
| E2 | 15 | 15 | 0.881 |
| E3 | 15 | 15 | 0.891 |
| E4 | 23 | 18 | 0.887 |
| E5 | 15 | 15 | 0.898 |

这里有一处方法学张力需要承认。用验证集选择轮次、再在独立测试集上报告性能，是标准做法。但六个臂各自独立选择轮次，等于给每个臂一次挑选有利轮次的机会，与固定轮次的比较并不严格等价。第 5.6 节把这一局限写清楚，并给出早期固定第 9 轮时的结果作为敏感性参照。

### 3.8 评价指标、校准与工作点

判别用 AUROC 与平均精度，概率质量另用 Brier 分数[20]。多任务臂的宏平均取八个终点的算术平均，单任务臂的宏平均就是该终点的值。两种口径的数值不可直接并列，第 4.2 节对此专门说明。

校准用期望校准误差，按式 (6) 计算，等宽分为十箱，空箱跳过。

$$\mathrm{ECE}=\sum_{m=1}^{M}\frac{|B_m|}{n}\left|\mathrm{acc}(B_m)-\mathrm{conf}(B_m)\right| \tag{6}$$

其中 $B_m$ 是第 $m$ 个分箱，$n$ 是样本数。本文同时报告按终点分别计算后再取算术平均的宏平均误差，以及把全部终点样本合并后的总体误差。前者对低患病率终点更敏感，后者被高患病率终点主导，两者都报可以避免单一数字掩盖结构。

温度缩放在从验证集内部切出的 64 张图像上拟合，与训练集、剩余验证图像与测试集均不相交。作为对照，本文另用全部 640 张验证图像拟合一次，并按终点分别拟合一次。

本文比较四种事后校正，全部只在验证集上读取或拟合。第一种是温度，一个参数。第二种是流行率偏移，把 logit 按式 (7) 平移，参数直接从验证集患病率读出，没有自由参数。

$$z'=z+\log\frac{\pi_{\mathrm{val}}}{1-\pi_{\mathrm{val}}} \tag{7}$$

第三种是只有一个平移量的拟合偏移，参数在验证集上最小化二元交叉熵得到。第四种是 Platt 标定，按式 (8) 给出斜率与截距两个参数。

$$p=\sigma(a\,z+b) \tag{8}$$

决策曲线用净收益，按式 (9) 计算，阈值范围取 0.05 至 0.50。

$$\mathrm{NB}=\frac{\mathrm{TP}}{n}-\frac{\mathrm{FP}}{n}\cdot\frac{p_t}{1-p_t} \tag{9}$$

工作点有两类。约登指数最大化灵敏度与特异度之和[21]。95% 特异度工作点取满足特异度下限的最高灵敏度。两类工作点都在 576 张验证图像上确定，阈值冻结后才

应用到测试集，另给出一个事后在测试集上匹配阈值的结果，作为任何阈值规则的上界。

### 3.9 统计推断

自助法区间用图像层级重采样，次数为 1000[22]。配对比较在同一批重采样索引上计算两个臂的 AUROC 之差，由此得到的差值区间反映配对结构。两条独立区间相减的做法会高估方差。DeLong 区间用结构分量法计算，多标签情形下取各终点有限区间的宏平均[23]。

本文没有做多重比较校正。全文的配对比较共四组，每一组都由一个预先指定的设计问题决定，挑选的成分很有限。区间下限贴近零的两组结果按边界证据表述，不写成确定结论。为避免宏平均被单一终点带动，另做了逐一剔除终点的稳健性检查，见第 4.3 节。

### 3.10 软件与复现

实现基于 PyTorch 2.7。特征提取与训练在单机完成，显卡为单卡。全部脚本、配置、指标与绘图代码见公开仓库。复现路径分三步，先构建特征缓存，再依次训练六个臂，最后汇总统计并生成图表。随机种子、划分文件与检查点随仓库发布。

## 4 结果

### 4.1 队列、质量分布与信息流

图 1 已给出方法的整体信息流。图 2 给出 RFMiD 真实眼底图像按软质量分层的示例，三行分别为好、可用与差，每行三例，图像来自真实像素，未经增强。图 3 给出测试集的软质量层级计数。

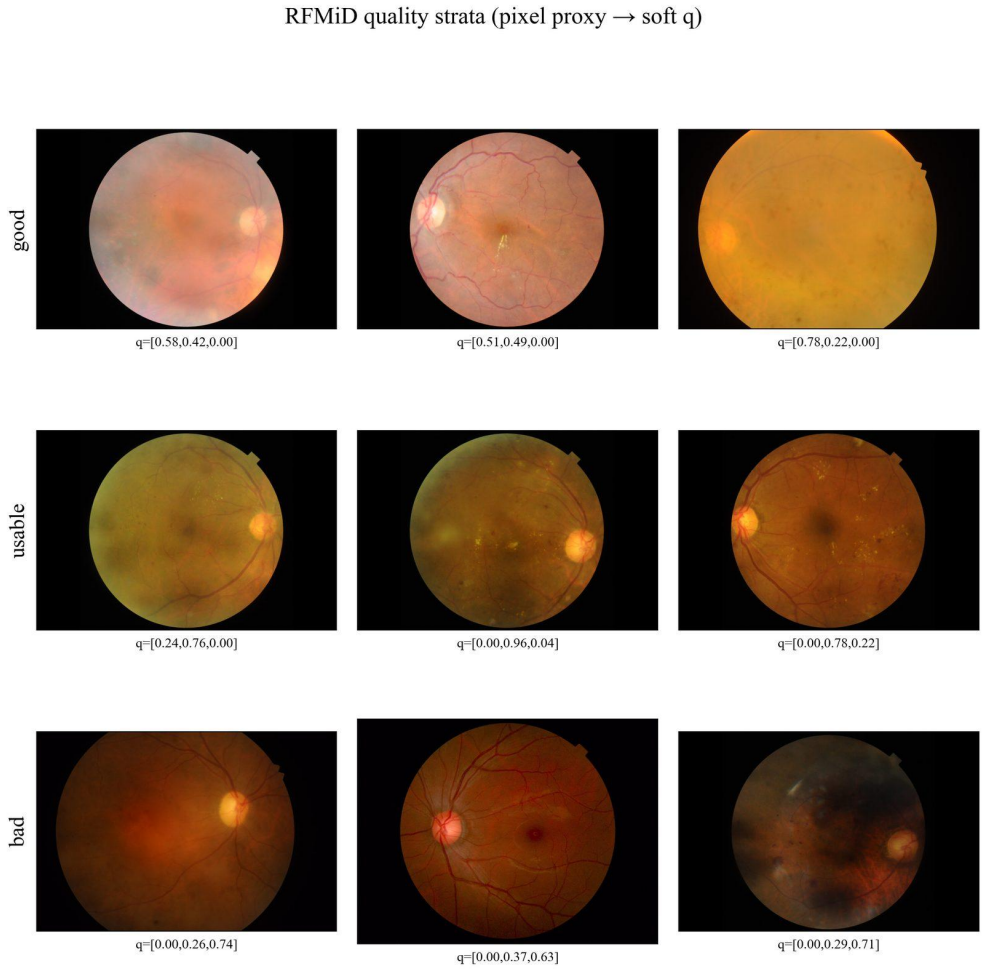



**图 2** RFMiD 真实眼底图像按软质量分层的示例。三行依次为好、可用与差，每行三例。图像取自真实像素，未做增强。

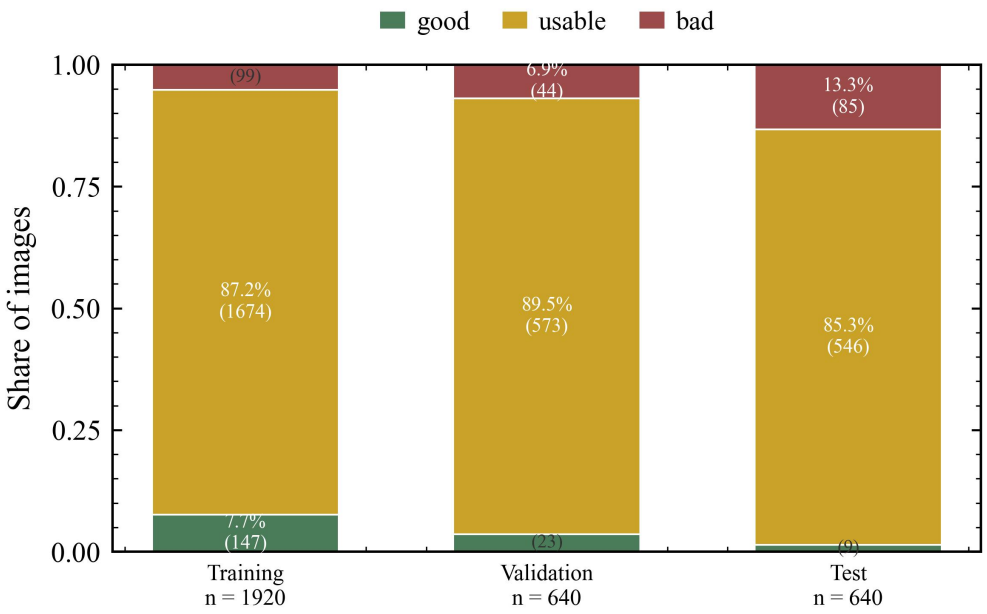



**图 3** 测试集软质量层级计数。好 9 张，可用 546 张，差 85 张。

可用层占绝大多数，差层次之，好层极少。这一分布本身值得注意。RFMiD 由多台相机采集，来源医院不同，刻意保留了不理想的采集，与社区筛查的真实情况接近。代价是好质量层在本数据上无法支撑独立估计，第 4.11 节只能比较可用层与差层。

## 4.2 主结果

表 3 给出六个实验臂在留出测试集上的主要指标。图 4 以柱状图呈现同一结果，误差棒为图像层级自助法 95% 区间。

**表 3** RFMiD 测试集主要指标。区间为图像层级自助法 95% 区间，重采样 1000 次。校准列为温度缩放之前的原始分数，缩放后的数值见第 4.5 节。

| 实验臂 | 宏平均 AUROC | 自助法区间 | DeLong 区间 | DR AUROC | 宏平均 AP | 平均分病种 ECE | Brier |
|---|---|---|---|---|---|---|---|
| E0 | 0.932 | 0.908 至 0.953 | 0.908 至 0.956 | 0.932 | 0.801 | 0.031 | 0.075 |
| E1 | 0.934 | 0.912 至 0.952 | 0.912 至 0.955 | 0.934 | 0.779 | 0.024 | 0.079 |
| E2 | 0.896 | 0.881 至 0.910 | 0.863 至 0.928 | 0.926 | 0.620 | 0.136 | 0.098 |
| E3 | 0.906 | 0.890 至 0.919 | 0.872 至 0.940 | 0.934 | 0.658 | 0.149 | 0.101 |
| E4 | 0.898 | 0.882 至 0.912 | 0.865 至 0.930 | 0.931 | 0.627 | 0.123 | 0.097 |
| E5 | 0.916 | 0.903 至 0.928 | 0.888 至 0.944 | 0.937 | 0.661 | 0.122 | 0.087 |

单任务臂的宏平均明显高于多任务臂。这一差异完全来自终点集合不同。E0 与 E1 只有糖尿病视网膜病变一个终点，其宏平均就是该终点的 AUROC。E2 至 E5 的宏平均把玻璃膜疣与近视性改变这类低患病率终点一起计入，分母更大。把 E0 的 0.932 与 E3 的 0.906 并列比较没有意义，正确的比较发生在同一终点集合内。

在同一终点上，多任务臂并不吃亏。糖尿病视网膜病变一列，E3 为 0.934，E5 为 0.937，都高于 E0 的 0.932。共享头没有牺牲主要终点，宏平均的下降来自新增的低患病率终点。这一点在后文的分终点分析中还要再确认一次。

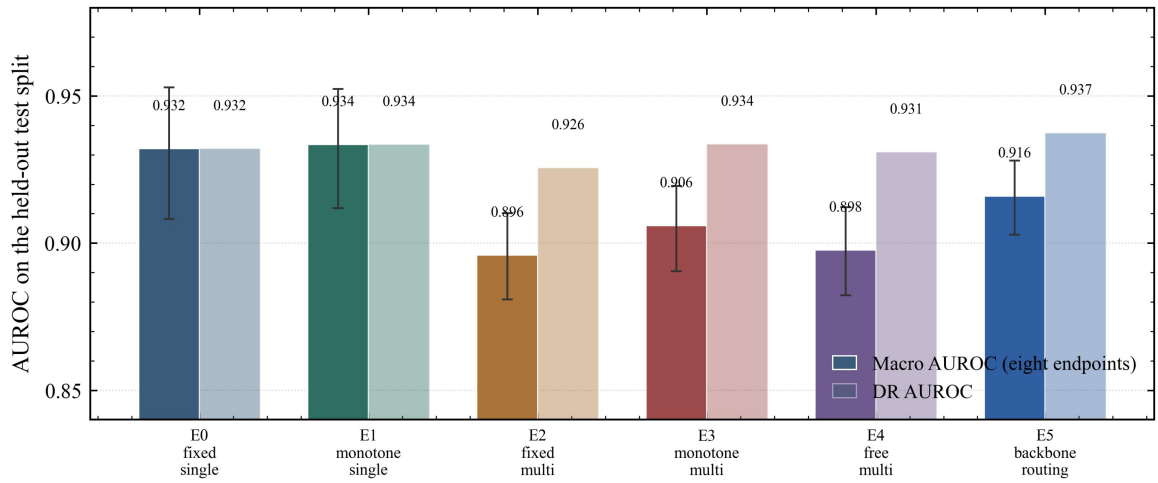



**图 4** 六个实验臂在测试集上的宏平均 AUROC 与糖尿病视网膜病变 AUROC。误差棒为图像层级自助法 95% 区间，仅宏平均配有区间。

### 4.3 配对比较与终点稳健性

只看点估计容易过度解读。表 4 与图 5 给出四组配对差值，全部在同一批重采样索引上计算。

**表 4** 配对 AUROC 差值。区间为同一批重采样索引下的配对自助法 95% 区间，重采样 1000 次。

| 比较 | 终点集合 | 差值 | 95% 区间 | 差值大于零的比例 |
|---|---|---|---|---|
| E1 减 E0 | DR | +0.001 | −0.017 至 +0.020 | 0.556 |
| E3 减 E2 | 宏平均 | +0.010 | −0.001 至 +0.021 | 0.961 |
| E3 减 E2 | 糖尿病视网膜病变 | +0.008 | −0.001 至 +0.017 | 0.959 |
| E4 减 E3 | 宏平均 | −0.008 | −0.020 至 +0.003 | 0.069 |
| E5 减 E3 | 宏平均 | +0.010 | +0.000 至 +0.021 | 0.975 |
| E5 减 E3 | 糖尿病视网膜病变 | +0.004 | −0.010 至 +0.018 | 0.719 |

第一组是本文最需要如实报告的结果。在单任务条件下把固定权重换成单调路由，糖尿病视网膜病变 AUROC 从 0.932 升到 0.934，配对区间从负值跨到正值，差值大于零的比例为 0.556，接近抛硬币。在 640 张测试图像上，这一点增益无法与零区分。

早期版本报告过同一比较的更大差距，那次用的是第 9 轮检查点。改用验证集选出的第 12 轮与第 14 轮后，基线本身提高了，两个臂的差距随之缩小。小样本上的点估计对轮次选择相当敏感，这一点在后文的局限中还要提到。

第二组与第五组给出方向一致的证据。多任务设置下，单调路由相对固定权重的宏平均差值为 +0.010，区间下限 −0.001，比例 0.961。加入骨干路由后差值为 +0.010，区间下限 +0.00005，比例 0.975。两组都属于边界证据，可以写成方向一致且区间下限贴近零，不能写成显著优于。

第三组是最直接的方法学证据。把单调路由换成自由线性路由，宏平均 AUROC 从 0.906 降到 0.898，差值为 −0.008，区间上限 +0.003，比例仅 0.069。也就是说，去掉顺序约束后有 93% 的重采样显示性能下降。

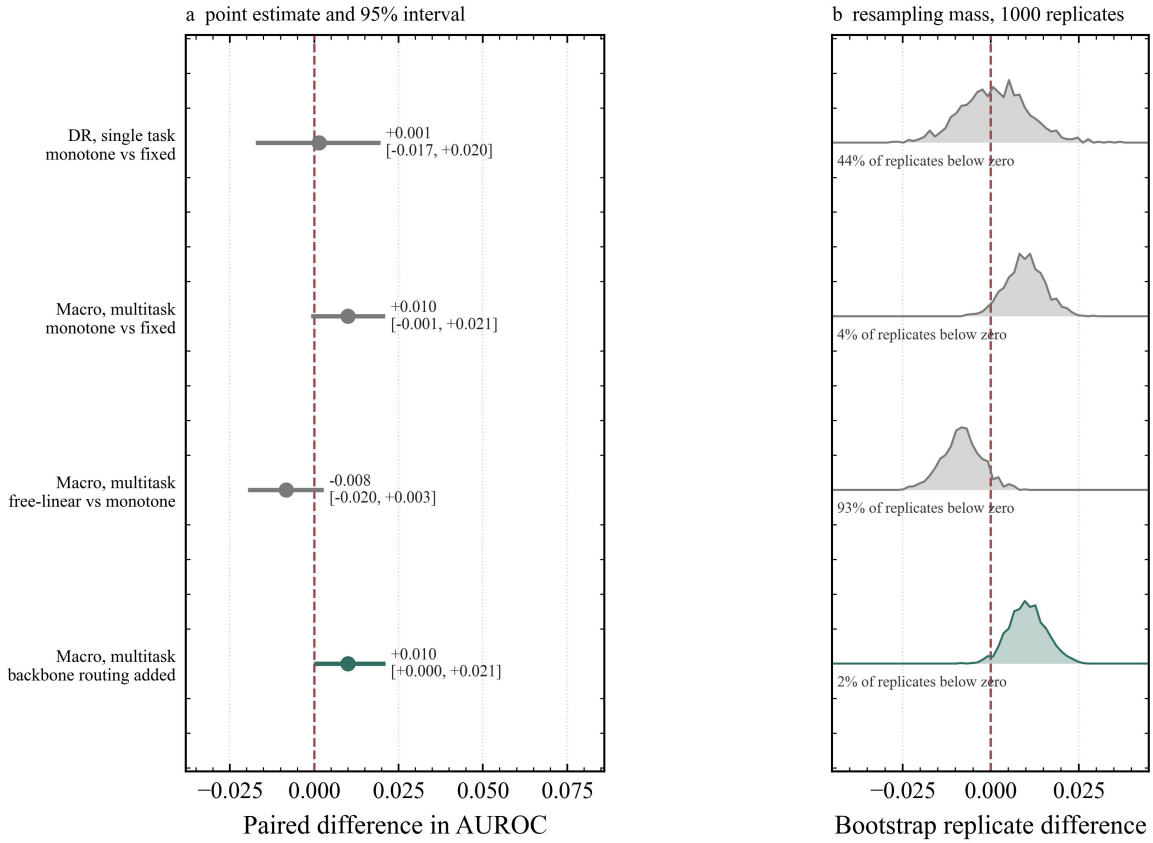



**图 5** 配对 AUROC 差值森林图与重采样分布。左图为点估计与 95% 区间，竖虚线为零，绿色表示区间不含零，灰色表示区间跨零。右图为 1000 次配对重采样的差值密度，阴影为落在零以下的部分。

图 5 右栏把点估计换成一个分布。E1 减 E0 有 44.4% 的重采样落在零以下，接近对称。E3 减 E2 只有 3.9%，E5 减 E3 只有 2.5%，两者的质量几乎全在零以上。E4 减 E3 有 93.1% 落在零以下。区间是否跨零和二值判断只差一点点，质量分布却把这三组证据的强弱分得很清楚。

宏平均把八个终点压成一个数，单个终点可能撑起整个差值。表 5 与图 6 给出逐一剔除一个终点后的结果。

**表 5** 逐步剔除单一终点后的宏平均差值。每次剔除一个终点，其余七个终点重新取算术平均。

| 比较 | 全终点差值 | 逐一剔除后的最小差值 | 逐一剔除后的最大差值 | 符号是否保持 |
|---|---|---|---|---|
| E3 减 E2 | +0.010 | +0.004 | +0.015 | 保持 |
| E4 减 E3 | −0.008 | −0.014 | −0.003 | 保持 |
| E5 减 E3 | +0.010 | +0.003 | +0.015 | 保持 |

三组比较在八次剔除中符号全部不变，幅度在 0.003 至 0.015 之间摆动。E3 减 E2 的差值在剔除视盘杯盘比异常后降到 +0.004，原因是该终点上 E3 相对 E2 的增益最大，为 +0.053。E5 减 E3 在剔除年龄相关性黄斑变性后降到 +0.003，该终点上 E5 的增益为 +0.060。换句话说，宏平均差值的符号不依赖任何一个终点，幅度却依赖终点构成。报告宏平均时应当同时给出这一层检查。

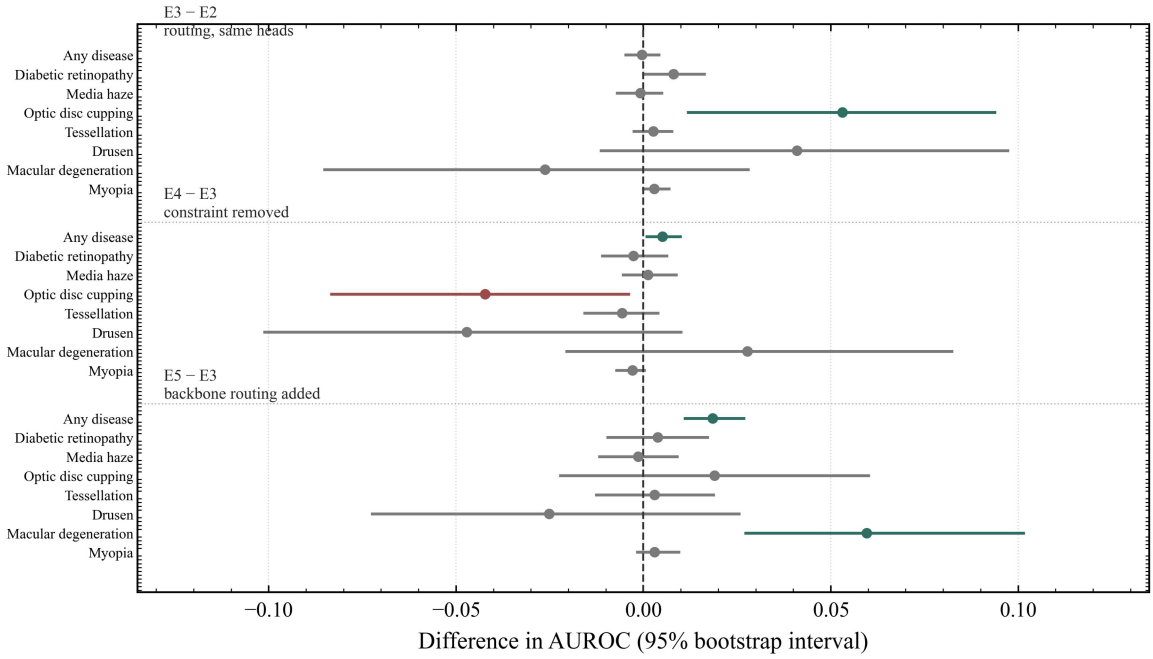



**图 6** 三组设计比较的分终点配对差值。点为差值，横线为 95% 自助法区间，绿色表示区间不含零。

分终点看，E3 相对 E2 的增益集中在视盘杯盘比异常与玻璃膜疣，分别是 +0.053 与 +0.041。E4 相对 E3 的下降集中在视盘杯盘比异常，为 −0.042。E5 相对 E3 的增益集中在任意病变与年龄相关性黄斑变性，分别是 +0.018 与 +0.060，两者的区间都不含零。同一组设计改动在不同终点上的作用方向并不一致，这是宏平均无法表达的信息。

### 4.4 分终点判别

表 6 给出 E5 在八个终点上的判别与校准，图 7 给出对应的 ROC 曲线。

**表 6** E5 在测试集上的分终点表现。患病率为测试集实际比例，区间为图像层级自助法 95% 区间。

| 终点 | AUROC | 95% 区间 | 平均精度 | 期望校准误差 | Brier | 患病率 |
|---|---|---|---|---|---|---|
| 任意病变 | 0.964 | 0.948 至 0.978 | 0.990 | 0.196 | 0.118 | 0.791 |
| 糖尿病视网膜病变 | 0.937 | 0.914 至 0.959 | 0.820 | 0.124 | 0.093 | 0.194 |
| 屈光介质混浊 | 0.959 | 0.934 至 0.978 | 0.882 | 0.119 | 0.082 | 0.162 |
| 视盘杯盘比异常 | 0.791 | 0.744 至 0.838 | 0.466 | 0.113 | 0.124 | 0.142 |
| 豹纹状眼底 | 0.932 | 0.906 至 0.955 | 0.481 | 0.110 | 0.083 | 0.083 |
| 玻璃膜疣 | 0.800 | 0.733 至 0.854 | 0.257 | 0.217 | 0.132 | 0.072 |
| 年龄相关性黄斑变性 | 0.954 | 0.921 至 0.980 | 0.533 | 0.064 | 0.044 | 0.048 |
| 近视性改变 | 0.990 | 0.982 至 0.996 | 0.856 | 0.033 | 0.023 | 0.050 |
| 宏平均 | 0.916 | — | 0.661 | 0.122 | 0.087 | — |

判别与平均精度在终点之间分化明显。近视性改变与年龄相关性黄斑变性的 AUROC 都在 0.95 以上，平均精度却差得很远，前者 0.856，后者 0.533。两者患病率都在 0.05 附近，阳性样本分别只有 32 例与 31 例，平均精度在这种稀疏条件下对分数分布非常敏感，一个高分阳性就能拉动明显。

视盘杯盘比异常与玻璃膜疣的 AUROC 在 0.79 至 0.80，是八个终点中最难的两项。这两项都依赖纤细的边界结构，视盘边界与玻璃膜疣的边缘在 224 像素输入下损失较大。ImageNet 替代骨干没有见过眼底图像，这一损失被进一步放大。

校准误差与患病率同向变化，成因在于 logit 中心的位置，单纯归到过度自信上并不准确。任意病变的阳性样本最多，误差 0.196，是八个终点中最高的。近视性改变最少，误差 0.033，是最低的。第 4.6 节会说明，这一排序对应的是 logit 中心与终点 logit 流行率之间的位置差，分数本身的整体锐度解释不了这一排序。

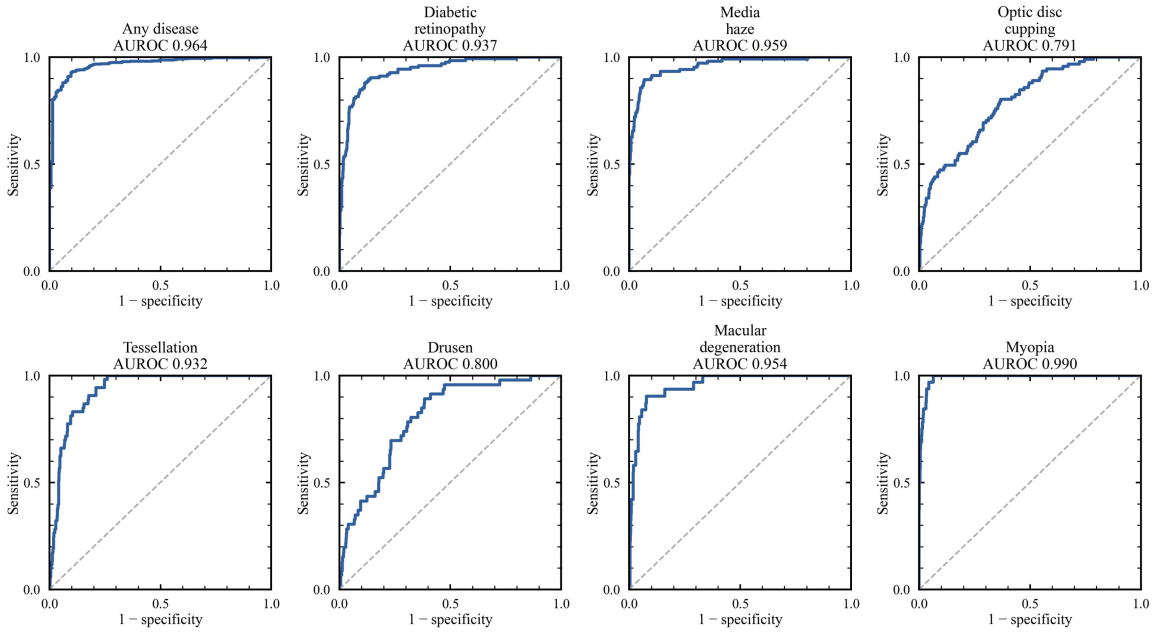



**图 7** E5 八个终点在测试集上的 ROC 曲线。括号内为 AUROC。

## 4.5 校准代价

表 7 按实验臂汇总校准指标。温度在每个臂的 64 张校准图像上拟合，这些图像从验证集切出，与训练集、验证集和测试集都不重叠。

**表 7** 校准指标。平均分病种 ECE 为八个终点 ECE 的算术平均，总体 ECE 为把全部终点样本合并后的单一值。温度在 64 张校准图像上拟合。

| 实验臂 | 拟合温度 | 校准集 ECE 前 | 校准集 ECE 后 | 测试集平均 ECE 前 | 测试集平均 ECE 后 | 最差终点 ECE | Brier 前 | Brier 后 |
|---|---|---|---|---|---|---|---|---|
| E0 | 1.099 | 0.090 | 0.104 | 0.031 | 0.035 | 0.031 | 0.075 | 0.075 |
| E1 | 1.325 | 0.086 | 0.088 | 0.024 | 0.030 | 0.024 | 0.079 | 0.079 |
| E2 | 1.216 | 0.122 | 0.134 | 0.136 | 0.152 | 0.239 | 0.098 | 0.099 |
| E3 | 1.261 | 0.133 | 0.148 | 0.149 | 0.168 | 0.275 | 0.101 | 0.103 |
| E4 | 1.382 | 0.112 | 0.130 | 0.122 | 0.147 | 0.236 | 0.097 | 0.098 |
| E5 | 1.132 | 0.105 | 0.112 | 0.122 | 0.132 | 0.217 | 0.087 | 0.088 |

单任务臂校准明显好于多任务臂。E0 的平均分病种误差为 0.031，E1 为 0.024。多任务臂升到 0.122 至 0.149，最差终点的误差在 0.217 至 0.275 之间。Brier 分数呈现同样的分组，单任务臂在 0.075 至 0.079，多任务臂在 0.087 至 0.101。

温度缩放在这张表上没有起到作用。六个臂拟合出的温度都大于 1，介于 1.099 与 1.382，方向是把分数往中间压。压过之后，测试集上的平均误差无一例外上升，升幅

从 0.004 到 0.024。Brier 分数变化很小，最大约 0.002。校准集上的误差同样是缩放后变差。

这一结果需要谨慎对待，因为它有两层含义。方法层上，温度只有一个自由度，只能修正分数的整体锐度。多任务臂的问题不在锐度，而在同一组融合特征被八个患病率相差一个数量级的终点共享，各终点的偏差方向不同。一个标量无法同时压平八个方向。估计层上，64 张校准图像用来拟合一个参数，样本太薄，拟合出的温度本身带有较大方差。

两层含义可以分开检验。表 8 把温度拟合的三种口径并列，分别是 64 张校准图像、576 张验证图像与逐终点拟合。最后再加一列在测试标签上直接拟合的逐终点温度，它用到了测试答案，只能当作上界。

**表 8** 温度拟合口径对照。校准列为 64 张独立校准图像，验证列为 576 张验证图像，逐终点列为同一 576 张图像上按终点各拟合一个温度。上界列用测试标签拟合逐终点温度，仅作参照。数值为八个终点期望校准误差的算术平均。

| 实验臂 | 原始 | 校准列拟合 | 验证列拟合 | 验证列逐终点 | 上界逐终点 |
|---|---|---|---|---|---|
| E0 | 0.031 | 0.035 | 0.028 | 0.028 | 0.030 |
| E1 | 0.024 | 0.030 | 0.033 | 0.033 | 0.029 |
| E2 | 0.136 | 0.152 | 0.141 | 0.142 | 0.133 |
| E3 | 0.149 | 0.168 | 0.155 | 0.154 | 0.143 |
| E4 | 0.122 | 0.147 | 0.138 | 0.134 | 0.126 |
| E5 | 0.122 | 0.132 | 0.124 | 0.124 | 0.117 |

表 8 的读法与表 7 不完全相同，差异本身是有信息的。把拟合样本从 64 张扩到 576 张，多任务臂的误差下降 0.008 至 0.013。单任务臂的表现则出现分化，E0 由 0.035 回到 0.028，E1 由 0.030 升到 0.033。这说明 64 张校准图像上的温度本来就不稳，扩大样本后部分臂的数值会改变，但改变的方向并不一致，幅度也不足以翻转结论。

关键的一列是上界。逐终点、且在测试标签上拟合，这已经是温度能做到的最好情况。多任务臂的上界为 0.117 至 0.143，相对原始值的变化落在 −0.004 至 +0.006 之间。给每个终点各配一个温度，误差仍然停在 0.12 附近。这条上界把锐度解释彻底排除。误差的来源不在尺度上，无论一个温度还是八个温度都碰不到它。

还有一个细节值得指出。E1 在三档拟合下都变差，上界也只有 0.029，略高于原始 0.024。E0 的原始分数本来就是六个臂中最平的，任何缩放都只会把它推向更差。这与第 4.7 节的流行率偏移结果一致，那条校正同样会让 E0 变差。两个方向都指向同一件事，单任务臂不存在需要事后修正的系统偏差。

为了排除分箱方式造成的假象，表 9 给出等宽分箱与等质量分箱的对照。

**表 9** 分箱方式敏感性。等质量分箱保证每个箱内样本数相同，等宽分箱把 0 至 1 均分。

| 实验臂 | 等宽分箱 ECE | 等质量分箱 ECE | 两者之差 |
|---|---|---|---|
| E0 | 0.031 | 0.037 | +0.006 |
| E1 | 0.024 | 0.020 | −0.004 |
| E2 | 0.136 | 0.136 | 0.000 |
| E3 | 0.149 | 0.149 | 0.000 |
| E4 | 0.123 | 0.123 | 0.000 |
| E5 | 0.122 | 0.122 | 0.000 |

两种分箱在多任务臂上给出几乎相同的数值，差异不超过 0.001。单任务臂的差异略大，E0 在等质量分箱下高 0.006，E1 低 0.004。这说明多任务臂的高误差不是分箱边界造成的，它在两种分箱下都存在。图 8 的可靠性图给出同一结论的图形形式。

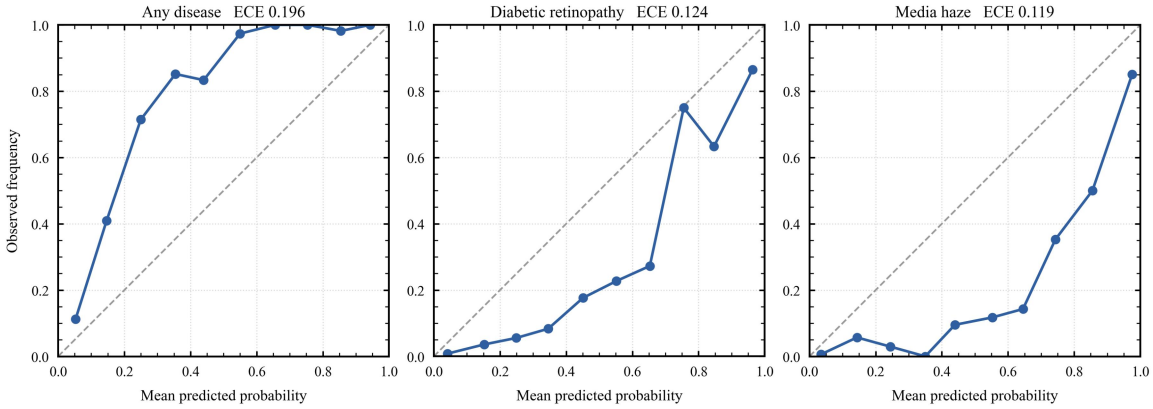



**图 8** E5 在任意病变、糖尿病视网膜病变与屈光介质混浊三个终点上的可靠性图。虚线为完美校准。低概率段的偏离不是斜率问题，温度缩放无法修正。

图 9 把 E3 与 E5 的分终点误差按患病率排序后并列。误差与患病率并不单调。玻璃膜疣的患病率为 0.072，误差 0.217，比患病率 0.142 的视盘杯盘比异常更高。

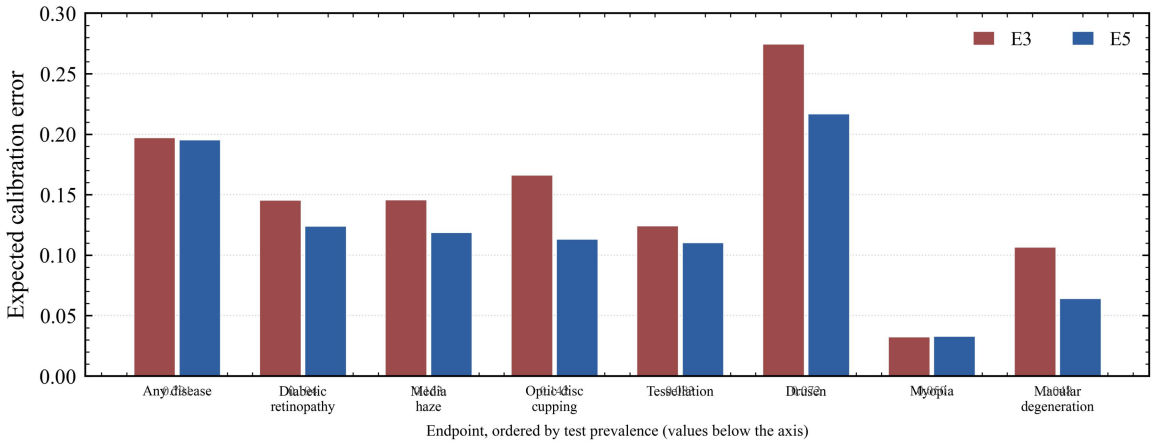



**图 9** E3 与 E5 的分终点期望校准误差。八个终点按患病率从左到右递减。

### 4.6 校准误差的来源

第 4.5 节排除了锐度与分箱两种解释，剩下的可能来源是分数分布的位置。表 10 直接检验这一点。对每个实验臂的每个终点，计算测试集上的平均 logit 与终点 logit 流行率 log(pi/(1-pi))，再看两者的相关系数与斜率。

**表 10** logit 中心与 logit 流行率的关系。缺口为平均 logit 减去 logit 流行率。相关系数与斜率在八个终点上计算。

| 实验臂 | 端点数 | 相关系数 r | 斜率 | 平均绝对缺口 | 最大绝对缺口 | 平均 ECE |
|---|---|---|---|---|---|---|
| E2 | 8 | 0.864 | 0.872 | 0.587 | 1.499 | 0.136 |
| E3 | 8 | 0.819 | 0.819 | 0.725 | 1.766 | 0.149 |
| E4 | 8 | 0.850 | 1.019 | 0.729 | 1.310 | 0.123 |
| E5 | 8 | 0.813 | 1.024 | 0.734 | 2.096 | 0.122 |

四个多任务臂的相关系数在 0.813 至 0.864，斜率在 0.819 至 1.024。也就是说，共享头的 logit 中心几乎按端点流行率一比一排列，整体上跟着流行率走，但每个终点上有 0.59 至 0.73 的平均绝对缺口。单任务臂不适用这一分析，只有一个端点，无法做跨端点回归。

斜率接近 1 是一个关键信息。如果斜率明显小于 1，说明分数被压扁，温度缩放就该有效。实测斜率在 0.82 至 1.02 之间，压缩比接近 1，说明各终点的分数没有整体变平，问题是每个终点的中心停在了错的位置。位置偏移不能靠改变锐度修正，这与表 8 的结果一致。

表 11 以 E5 为例给出逐个终点的数值。

**表 11** E5 的分终点 logit 偏移。logit 流行率与平均 logit 均在测试集上计算，拟合偏移为在验证集上最小化二元交叉熵得到的单参数平移。

| 终点 | 患病率 | logit 流行率 | 平均 logit | 缺口 | 拟合偏移 | ECE 原始 | ECE 流行率偏移 | ECE Platt |
|---|---|---|---|---|---|---|---|---|
| 任意病变 | 0.791 | +1.33 | +0.54 | −0.79 | +1.48 | 0.196 | 0.073 | 0.038 |
| 糖尿病视网膜病变 | 0.194 | −1.43 | −1.18 | +0.24 | −1.63 | 0.124 | 0.031 | 0.022 |
| 屈光介质混浊 | 0.163 | −1.64 | −1.59 | +0.05 | −1.17 | 0.119 | 0.024 | 0.043 |
| 视盘杯盘比异常 | 0.142 | −1.80 | −1.54 | +0.26 | −1.33 | 0.113 | 0.069 | 0.027 |
| 豹纹状眼底 | 0.083 | −2.40 | −2.50 | −0.10 | −1.81 | 0.110 | 0.039 | 0.025 |
| 玻璃膜疣 | 0.072 | −2.56 | −1.27 | +1.29 | −2.33 | 0.217 | 0.028 | 0.009 |
| 年龄相关性黄斑变性 | 0.048 | −2.98 | −4.02 | −1.05 | −1.97 | 0.064 | 0.025 | 0.016 |
| 近视性改变 | 0.050 | −2.94 | −5.04 | −2.10 | −2.30 | 0.033 | 0.021 | 0.017 |

缺口的方向与大小在终点之间差别很大。玻璃膜疣的平均 logit 比流行率高 1.29，属于明显的过度自信。近视性改变低 2.10，属于明显的过度保守。同一组共享特征上同时出现这两种反向偏差，一个全局标量温度自然无法同时修正。在验证集上拟合出的单参数偏移与 logit 流行率的相关系数为 0.967，说明拟合出来的平移量本身就在追踪流行率，这为下一节那条零参数校正提供了依据。

## 4.7 事后校正阶梯

如果误差主要来自位置，那么只用验证集患病率的偏移应该就能消掉大部分。表 12 把七档结果并列，包括原始分数与六种校正，全部只在验证集上读取或拟合。

**表 12** 事后校正阶梯。所有校正只在验证集上拟合或读取，测试集仅用于评分。数值为八个终点 ECE 的算术平均。共享 Platt 一列用全部终点共拟合的一对斜率与截距。

| 实验臂 | 原始 | 温度 | 流行率偏移 | 拟合偏移 | Platt | 保序回归 | 共享 Platt |
|---|---|---|---|---|---|---|---|
| E0 | 0.031 | 0.025 | 0.068 | 0.037 | 0.033 | 0.038 | 0.033 |
| E1 | 0.024 | 0.031 | 0.077 | 0.028 | 0.032 | 0.025 | 0.032 |
| E2 | 0.136 | 0.141 | 0.038 | 0.038 | 0.028 | 0.027 | 0.084 |
| E3 | 0.149 | 0.152 | 0.036 | 0.035 | 0.029 | 0.026 | 0.092 |
| E4 | 0.123 | 0.133 | 0.050 | 0.038 | 0.030 | 0.031 | 0.091 |
| E5 | 0.122 | 0.124 | 0.039 | 0.031 | 0.025 | 0.029 | 0.083 |

结果分成两组。多任务臂上，流行率偏移把误差从 0.136、0.149、0.123、0.122 分别降到 0.038、0.036、0.050、0.039，降幅为 0.072 至 0.113。这条校正只有一个从验

证集患病率读出的数，没有任何可调参数。加上一个斜率参数的 Platt 标定再降到 0.028 至 0.030，边际收益只有约 0.008。

单任务臂上，同一条校正反而有害。E0 从 0.031 升到 0.068，E1 从 0.024 升到 0.077。原因在表 11 的缺口结构里。单任务臂只有一个终点，它的输出已经对齐了该终点的流行率，再加一次流行率偏移等于把中心推过头。这一对照说明校正的适用范围由数据决定，不能不加区分地套用。

还有一层对照说明位置偏移必须按终点处理。把八个终点的全部样本合在一起，拟合一对共享的 Platt 参数，一个斜率加一个截距。多任务臂的平均误差从 0.122 至 0.149 降到 0.083 至 0.092，降幅约三成。逐终点平移只用八个患病率数值，误差落到 0.036 至 0.050。共享映射的两个参数确实在动，方向也对，但它只有一个截距，八个不同位置不可能同时对准。共享斜率在多任务臂上拟合到 0.734 至 0.915，低于 1，说明共享映射还把分数整体压扁了一点。位置与尺度被绑在同一对参数上，两头都只能取折中。

图 10 左侧把各档校正并列，右侧把拟合偏移对 logit 流行率作散点。四个多任务臂的点几乎落在对角线上，说明拟合出来的平移量就是流行率本身。

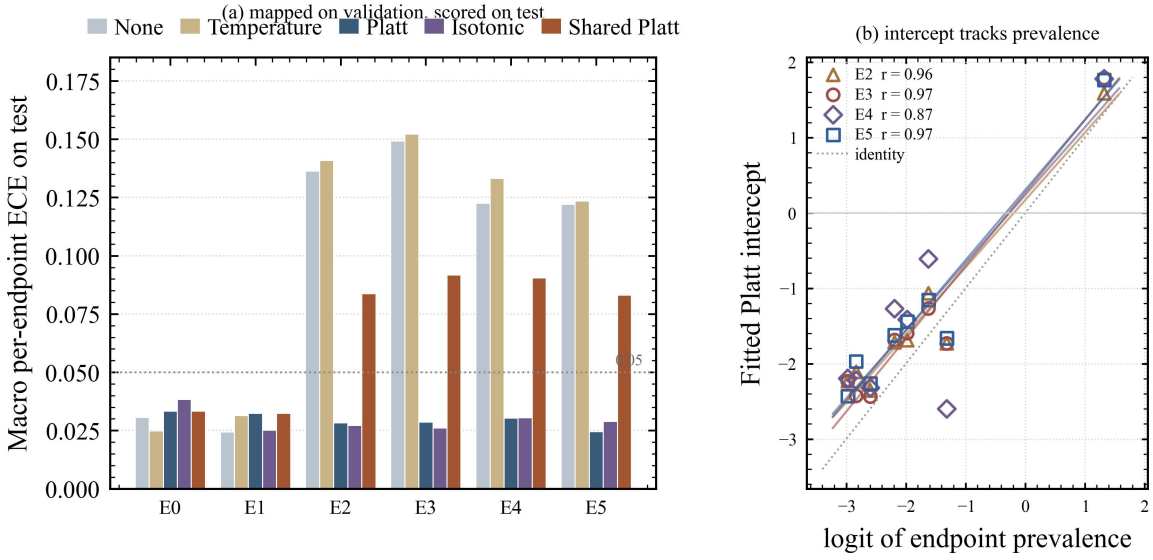



**图 10** 事后校正阶梯与偏移诊断。左图为五档结果的测试集平均分病种 ECE，依次为原始分数、温度、Platt、保序回归与共享 Platt，右图为各终点在验证集上拟合出的平移量对 logit 流行率。

温度缩放与保序回归的表现值得单独比较。温度在六个臂上全部无效，保序回归在多任务臂上接近 Platt，在单任务臂上与原始分数持平甚至略差。保序回归作为非参数做法在较早的对比研究中已被系统评估[24]。它的代价是判别略有损失，E5 的宏平

均 AUROC 从 0.916 降到 0.908，E4 从 0.898 降到 0.879。Platt 与流行率偏移都是单调变换，AUROC 完全不变。这一差别在只需要概率的场合影响不大，在同时报告判别与概率的场合需要说明。

图 11 把温度缩放前后的宏平均 AUROC 与平均校准误差画在一起，可以看到判别完全不动，误差在缩放后略有上升。

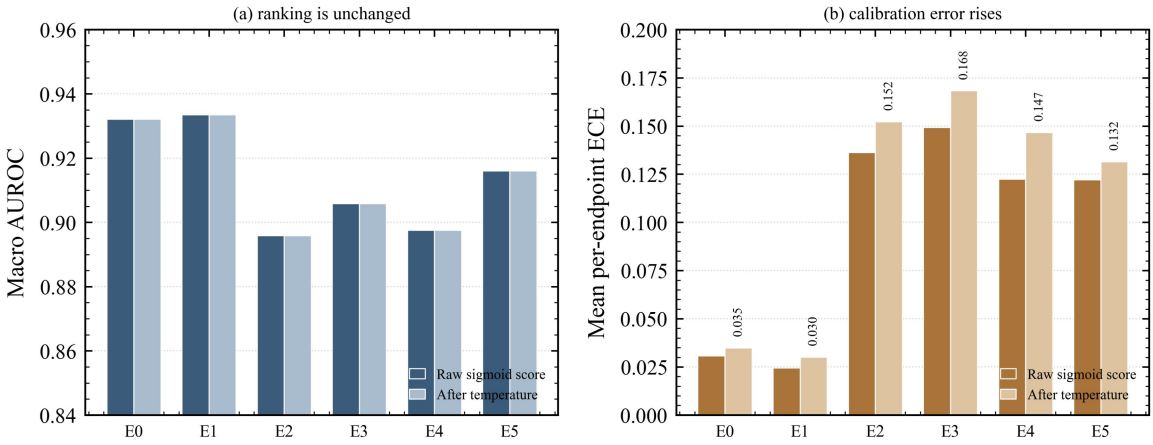



**图 11** 温度缩放前后的宏平均 AUROC 与平均分病种 ECE。左图显示判别完全不变，右图显示校准误差在缩放后略有上升。

### 4.8 工作点与阈值搬移

表 13 给出约登工作点，阈值在 576 张验证图像上确定，冻结后应用到测试集。

**表 13** 约登工作点。阈值在验证集上确定，测试集只用于评价。

| 实验臂 | 阈值 | 验证集灵敏度 | 验证集特异度 | 测试集灵敏度 | 测试集特异度 |
|---|---|---|---|---|---|
| E0 | 0.239 | 0.908 | 0.821 | 0.855 | 0.868 |
| E1 | 0.402 | 0.782 | 0.919 | 0.766 | 0.920 |
| E2 | 0.591 | 0.885 | 0.857 | 0.790 | 0.878 |
| E3 | 0.542 | 0.885 | 0.837 | 0.863 | 0.851 |
| E4 | 0.760 | 0.877 | 0.857 | 0.798 | 0.891 |
| E5 | 0.487 | 0.902 | 0.844 | 0.879 | 0.884 |

约登工作点上的结果比较平稳。六个臂在验证集上的灵敏度介于 0.782 与 0.908，冻结到测试集后介于 0.766 与 0.879。E5 在该工作点上的测试集灵敏度 0.879、特异度 0.884，是六个臂中最均衡的一个。E3 的测试集灵敏度 0.863 与 E5 接近，特异度低 0.033。

高特异度工作点的情况复杂得多。表 14 给出 95% 特异度下的结果，最后一列是为了对照而计算的事后上界，训练与验证流程不使用它。

**表 14** 高特异度工作点。阈值为满足 95% 特异度下限的最高灵敏度所对应的截断值。事后上界灵敏度直接用测试标签匹配该特异度，仅作对照。

| 实验臂 | 验证集阈值 | 验证集灵敏度 | 测试集灵敏度 | 测试集特异度 | 事后上界灵敏度 | 搬移落差 |
|---|---|---|---|---|---|---|
| E0 | 0.564 | 0.723 | 0.661 | 0.957 | 0.677 | 0.016 |
| E1 | 0.517 | 0.706 | 0.645 | 0.950 | 0.637 | −0.008 |
| E2 | 0.787 | 0.697 | 0.653 | 0.950 | 0.653 | 0.000 |
| E3 | 0.830 | 0.672 | 0.581 | 0.955 | 0.597 | 0.016 |
| E4 | 0.890 | 0.689 | 0.629 | 0.952 | 0.629 | 0.000 |
| E5 | 0.836 | 0.705 | 0.540 | 0.971 | 0.766 | 0.226 |

若只在测试集上挑选满足 95% 特异度的最高灵敏度，E5 得到 0.766，比 E0 的 0.677 高 0.089。这个数字在早期版本里被当成了 E5 的优势证据。它站不住，因为挑选阈值的动作用到了测试标签。

把阈值冻结在验证集之后，E5 的测试集灵敏度降到 0.540，实际特异度升到 0.971。E0 由 0.723 落到 0.661，实际特异度 0.957。E5 比 E0 低 0.121，配对自助法区间为 −0.192 至 −0.050，整个区间在零以下。按可部署的规则评价，E5 在这个工作点上反而最差。

原因可以在分数分布里看到。图 12 给出同一工作点上两种口径的对照。图 13 给出六个臂的糖尿病视网膜病变阴性分数在验证集与测试集上的密度。E0 的两条曲线几乎重合，E5 的测试集曲线明显左移。验证集上 0.836 的阈值冻结过去，落在测试集阴性分布已经变稀的位置，特异度因此被动升高，灵敏度随之损失。

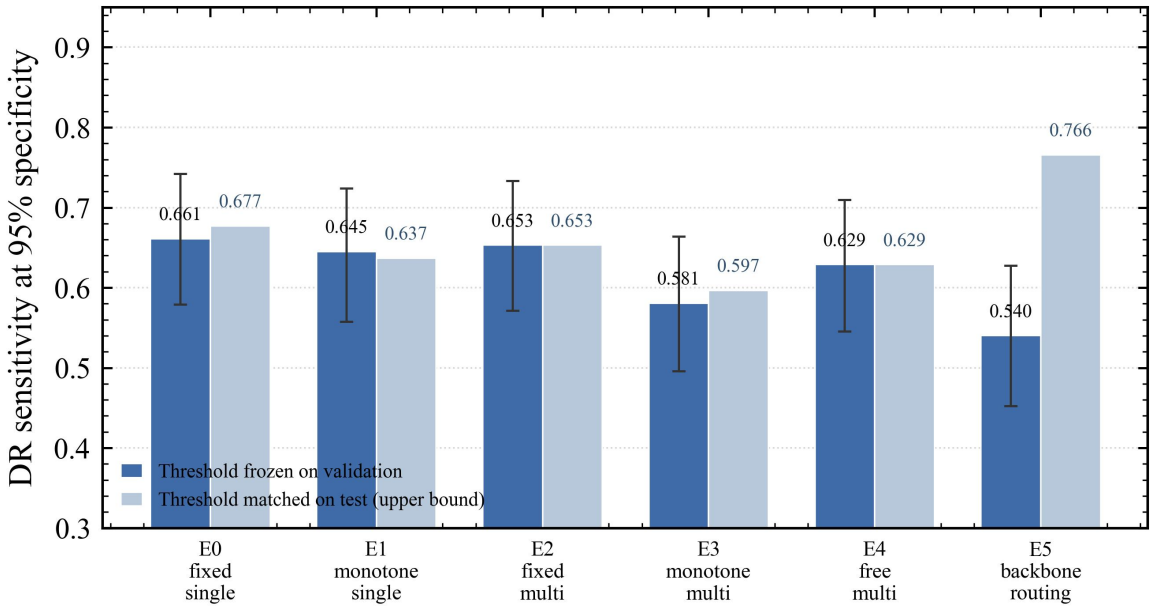



**图 12** 95% 特异度工作点上的糖尿病视网膜病变灵敏度。浅色为验证集阈值冻结后的测试集结果，深色为在测试集上事后匹配特异度的上界。

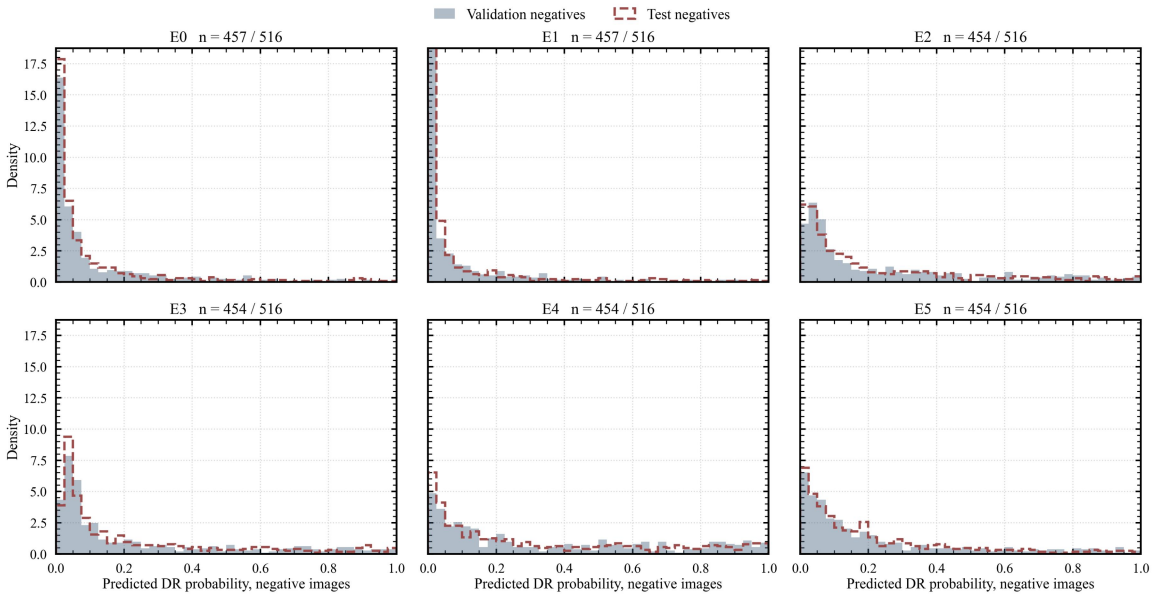



**图 13** 糖尿病视网膜病变阴性样本的预测分数密度。实线为验证集，虚线为测试集。E5 的测试集曲线左移最明显。

这一现象提醒一件事。只看一个工作点的灵敏度，很容易把阈值漂移读成模型优劣。表 14 的落差列把两者分开。落差越大，说明分数分布在两个集合之间越不一致，判别力本身并不随之提高。E5 的上界 0.766 与冻结后的 0.540 相差 0.226，是六个臂中最大的。E2 与 E4 的落差为 0.000，说明它们的分数分布在两个集合上几乎一致，代价是它们的上界本身也不高。

一个折中的读法是同时看两个口径。E5 的上界最高，说明它的排序能力在该工作点上确实最强。E5 的冻结结果最低，说明把阈值从一个集合搬到另一个集合时它最不稳。前者关于判别，后者关于可部署性，两者都是真实存在的性质。

### 4.9 临床效用

表 15 把同一组冻结阈值换算成筛查流程里更直观的量。TP、FP、TN、FN 是测试集 640 张上的实际计数，PPV 与 NPV 是它们的比值，后两列按每 100 名受检者折算。

**表 15** 固定工作点上的临床效用。阈值来自表 14，测试集 640 张，患病率 0.194。

| 实验臂 | TP | FP | TN | FN | PPV | NPV | 每百人漏诊 | 每百人误报 |
|---|---|---|---|---|---|---|---|---|
| E0 | 82 | 22 | 494 | 42 | 0.788 | 0.922 | 6.56 | 3.44 |
| E1 | 80 | 26 | 490 | 44 | 0.755 | 0.918 | 6.88 | 4.06 |
| E2 | 81 | 26 | 490 | 43 | 0.757 | 0.919 | 6.72 | 4.06 |
| E3 | 72 | 23 | 493 | 52 | 0.758 | 0.905 | 8.12 | 3.59 |
| E4 | 78 | 25 | 491 | 46 | 0.757 | 0.914 | 7.19 | 3.91 |
| E5 | 67 | 15 | 501 | 57 | 0.817 | 0.898 | 8.91 | 2.34 |

E5 的 PPV 最高，为 0.817，误报最少，每 100 人 2.34 例。代价是漏诊最多，每 100 人 8.91 例，比 E0 的 6.56 例多出 2.35 例。在筛查场景里这两类错误的权重并不对等。漏掉一个可干预的糖尿病视网膜病变，后果通常重于多转诊一次。按这个权重，E5 在这个工作点上难以算作更好的选择。

E0 的 PPV 0.788、NPV 0.922，漏诊 6.56、误报 3.44，是六个臂中最平衡的一组。这与它的宏平均 AUROC 最高同时成立，但两者描述的内容并不相同。AUROC 只描述排序，这里的计数描述的是某个具体截断值下的后果。

### 4.10 决策曲线

图 14 给出 E5 在四个终点上的决策曲线。横轴为阈值概率，纵轴为净收益，三条线分别是模型、全部治疗与全部不治疗。

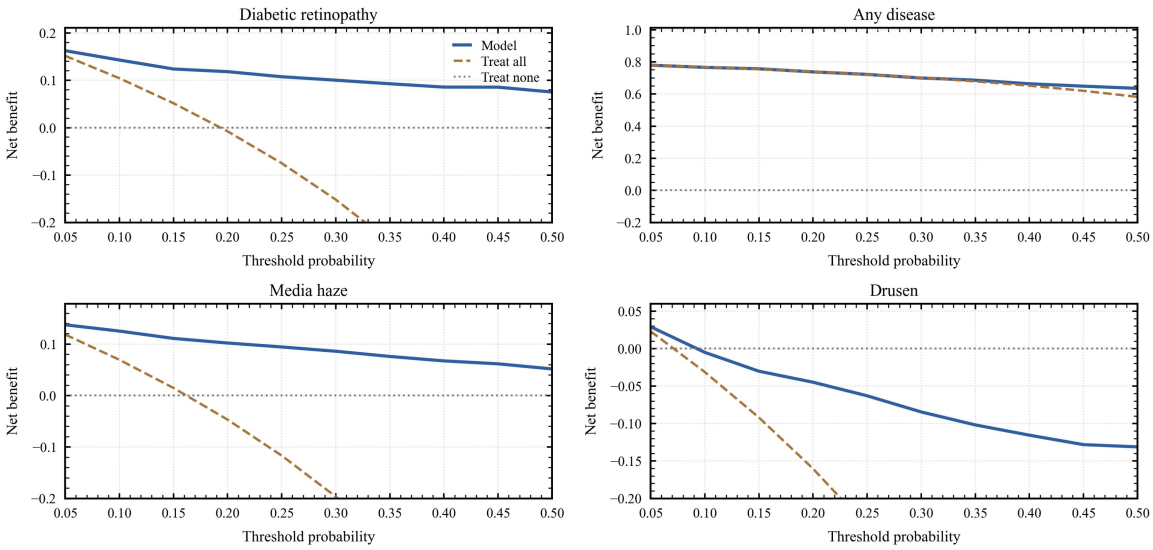



**图 14** E5 在糖尿病视网膜病变、任意病变、屈光介质混浊与玻璃膜疣上的决策曲线。全部不治疗的净收益恒为零。

在糖尿病视网膜病变上，模型曲线在 0.05 至 0.50 的整个范围内都高于全部治疗。阈值 0.10 处模型净收益 0.143，全部治疗为 0.104。阈值 0.30 处模型为 0.100，全部治疗已降到 −0.152。曲线的下降速度与患病率一致，该终点患病率 0.194，全部治疗在 0.20 附近穿过零点。

与其他臂相比，E0 在这条曲线上略占优势。阈值 0.10 处 E0 为 0.155，E5 为 0.143。阈值 0.50 处 E0 为 0.094，E5 为 0.075。差距不大，方向与宏平均 AUROC 的排序一致。

任意病变的曲线形状不同。该终点患病率 0.791，全部治疗在阈值 0.80 以上才失去优势，而绘图区间只到 0.50，因此两条线在整个区间内几乎重合。阈值 0.50 处模型 0.634，全部治疗 0.581，差距 0.053。这一终点的临床用途偏向排除，不是确诊。

玻璃膜疣的曲线不支持效用结论。阈值超过 0.05 之后模型净收益转为负值，从 −0.005 一路降到 −0.131。该终点患病率 0.072，阳性样本 46 例，小阈值处的抽样误差明显。图注中标注了这一点，避免把它读成稳定的效用结论。

### 4.11 质量分层

表 16 与图 15 给出按软质量分层的宏平均 AUROC。好质量层只有 9 张图像，无法估计，表中省略。

**表 16** 按软质量分层的宏平均 AUROC。分层依据为融合质量向量的最大值。可用层 546 张，差层 85 张。

| 实验臂 | 可用层 AUROC | 差层 AUROC | 两层差值 |
|---|---|---|---|
| E0 | 0.929 | 0.947 | +0.018 |
| E1 | 0.931 | 0.930 | −0.001 |
| E2 | 0.890 | 0.935 | +0.044 |
| E3 | 0.901 | 0.951 | +0.050 |
| E4 | 0.891 | 0.941 | +0.050 |
| E5 | 0.910 | 0.953 | +0.043 |

初看之下，差层的 AUROC 高于可用层，似乎是模型在劣质图像上反而更准。这一解读不成立。两层的病例构成不同，差层的糖尿病视网膜病变患病率为 0.082，可用层为 0.212，相差 2.6 倍。差层里阳性样本更少，而 AUROC 在阳性稀缺时对少数高分阳性更敏感，数值容易偏高。

这一发现对质量路由的解读有直接影响。多任务臂在差层的 AUROC 都在 0.935 以上，看起来像是质量路由起了作用。但两层患病率的差异说明，更可能的解释是差层样本本身更容易区分。第 4.12 节的推理期干预给出同一结论的另一条证据。

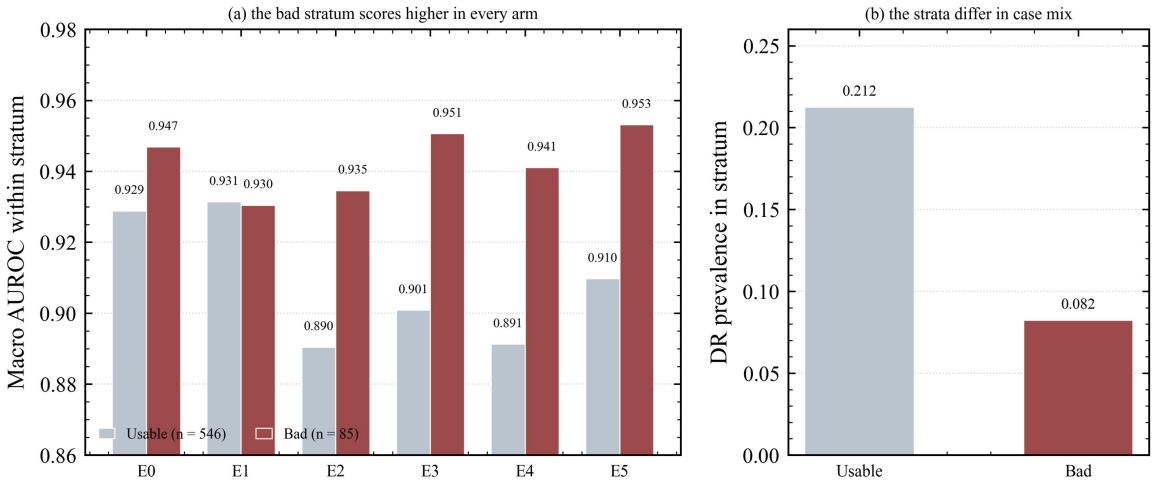



**图 15** 可用层与差层的宏平均 AUROC。柱上数字为点估计，横轴标注样本量。好质量层仅 9 张，未纳入。

## 4.12 路由器的实际取值与推理期干预

表 17 给出训练后路由器的三个权重，以及把权重在推理期强制改回固定值后的变化。

**表 17** 路由器的实际取值与推理期干预。权重按好质量归一化到 1。最大偏离为三个权重相对固定基线的最大绝对差。钳制后 AUROC 变化为把权重改回 1、0.5、0 后的测试集宏平均差值。

| 实验臂 | 好质量权重 | 可用质量权重 | 差质量权重 | 最大偏离 | 钳制后 AUROC 变化 | 最大概率变化 |
|---|---|---|---|---|---|---|
| E0 | 1.000 | 0.500 | 0.000 | 0.000 | — | — |
| E1 | 1.000 | 0.501 | 0.000 | 0.001 | $3.1\times10^{-5}$ | 0.001 |
| E3 | 1.000 | 0.504 | 0.000 | 0.004 | $1.9\times10^{-5}$ | 0.007 |
| E4 | 1.000 | 0.506 | −0.002 | 0.010 | $1.9\times10^{-5}$ | 0.036 |
| E5 | 1.000 | 0.506 | 0.000 | 0.006 | $4.1\times10^{-6}$ | 0.008 |

三个单调路由臂都停在初始化附近。差质量权重保持在 $10^{-4}$ 量级，可用质量权重在 0.501 至 0.506，好质量权重恒为 1。最大偏离为 0.001 至 0.006。自由线性路由偏离得更远，为 0.010，而且差质量权重落到了负值 −0.002。

推理期干预的结果更直接。把路由器参数改回固定值后，E5 的宏平均 AUROC 只变化 $4.1\times10^{-6}$，单图概率最大变化 0.008。E4 的概率变化最大，为 0.036，AUROC 变化仍只有 $1.9\times10^{-5}$。

这组数字改变了我们对 E3 与 E5 增益来源的解释。既然推理期的权重改写几乎不改变输出，那么 E3 相对 E2 的 +0.010 就不太可能来自质量权重的重新分配。更合理的解释是训练轨迹的改变。单调路由在训练中给融合标量施加了一个幅度很小、方向受限的扰动，E3 的平均扰动为 0.003，E4 为 0.008，E5 为 0.004。这个扰动改变了共享头在该扰动下的梯度路径，最终落在一个略好的局部解。

E4 的结果支持同一解释的反面。自由线性路由允许更大的扰动，平均 0.008，最大单图扰动 0.010，结果性能下降 0.008。扰动更大并没有带来更好的解，说明单调约束的价值在于限制扰动幅度并保持方向，不在于让模型学到一套新的质量权重。图 16 把两条证据画在一起，左侧是四个实验臂在三个质量层级上的权重偏离，右侧是钳制前后的概率与判别变化。左图里单调臂的柱高几乎贴住零线，右图里钳制的两条柱高也接近零。

E5 的增益机制不同于 E3。骨干路由器含两层感知机，参数更多，因此 E5 相对 E3 的 +0.010 可能来自质量条件，也可能只是多了一个可训练层。表 18 用三种推理期替换把这两种可能分开。

**表 18** E5 骨干路由器的推理期替换。均匀混合把 softmax 输出替换为三个三分之一，保留架构与全部权重。清零路由器把最后一层权重与偏置归零，等价于训练初始状态。质量置换把质量向量在图像之间随机打乱，重采样 10 次。相对训练后一列为与训练后宏平均 AUROC 之差。

| 替换方式 | 宏平均 AUROC | 相对训练后 | 最大单图概率变化 |
|---|---|---|---|
| 训练后 | 0.916 | — | — |
| 均匀混合 | 0.916 | +0.0001 | 0.175 |
| 清零路由器 | 0.916 | +0.0001 | 0.175 |
| 质量置换 | 0.912 | −0.004 | — |

三个骨干上的权重几乎不随图像变化。Swin 槽平均 0.385，标准差 0.0043，变异系数 1.1%。RETFound 槽平均 0.271，标准差 0.0044。Vim 槽平均 0.344，标准差 0.0020。三条权重在全部测试图像上的取值范围最宽的也只有 0.019。路由器学到的接近一个常数混合比例，几乎没有读入质量向量。

把 softmax 输出替换成均匀的三分之一，宏平均 AUROC 只变化 0.0001。清零路由器参数得到同一个数值，因为零初始化对应的正是均匀混合。两个替换都保留架构与其余全部权重，因此这条对照说明 E5 相对 E3 的增益与质量条件无关，来源是那一层参数本身。

质量置换的结果需要谨慎读。它让宏平均 AUROC 降到 0.912，比训练后低 0.004，比均匀混合也低。原因在于质量向量在 E5 里被用了两次，一次进骨干路由器，一次进每个骨干块内部的双线性融合。打乱质量向量同时扰动这两条通路，因此它无法单独归因到骨干路由器。均匀混合才是干净的那一条对照。

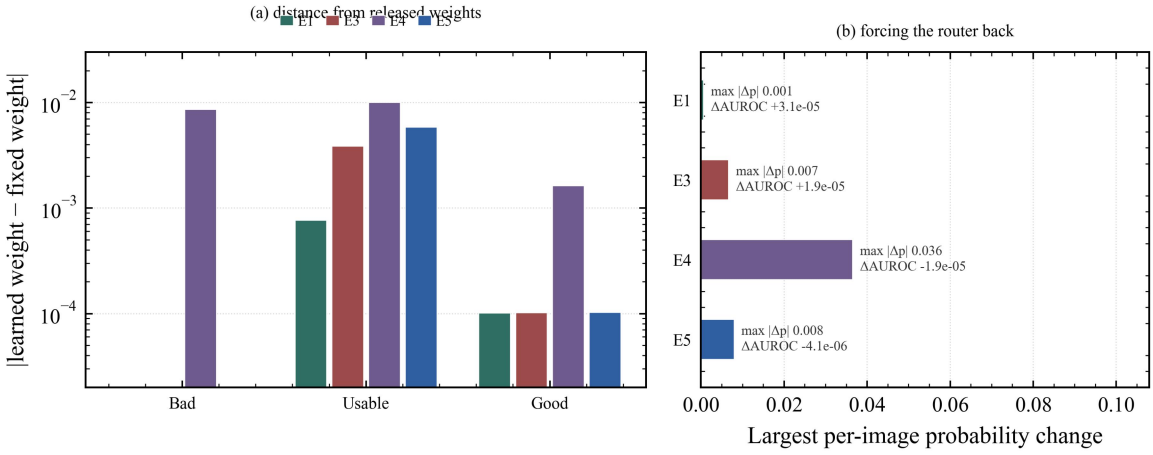



**图 16** 路由器的偏离与钳制效应。左图为各质量层级上学习权重与固定权重之差的绝对值，纵轴为对数尺度。右图为把权重强制改回固定值后单图概率的最大变化与宏观 AUROC 变化。

质量通路本身还有一层检验。把每张图像的质量向量替换为固定的三分之一，四个臂的宏平均 AUROC 几乎没有变化。E2 从 0.896 变到 0.895，E3 从 0.906 变到 0.905，E4 从 0.898 变到 0.897，E5 从 0.916 变到 0.916。四个臂的变化都在 0.001 以内，而单图概率最大变化达到 0.41 至 0.64。质量向量改变了概率的绝对水平，几乎没有改变排序。

这组数字把全文的机制解释收拢到一点。质量信息在训练阶段参与了参数更新，在推理阶段对排序的贡献很小。E3 相对 E2 的 +0.010 与 E5 相对 E3 的 +0.010 都出自训练轨迹，来自运行时的质量加权可以排除。判断这类模块时，推理期替换比查看学到的权重更有信息量。

# 5 讨论

## 5.1 主要发现

本文在 RFMiD 真实像素上比较了六个实验臂。五点结论比较稳固。

第一，多任务学习与质量路由的组合带来方向一致的宏平均增益。E3 相对 E2 为 +0.010，E5 相对 E3 为 +0.010，两组区间下限都贴近零。这两组不足以支撑强断言，但两组独立比较方向相同，逐一剔除任一终点后符号不变，且 E5 在 Brier 与全部分终点平均误差上都占优，合起来构成一致证据。

第二，单调约束的去留会改变结果。E4 相对 E3 为 −0.008，93% 的重采样显示下降，剔除任一终点后仍为负。这是本文最直接的方法学证据，也回答了第 1.2 节提出的第一个问题。需要限定的是，E4 与 E3 的差别只在参数化方式，两者的训练预算相同，因此这条证据说明的是本次条件下约束有用，不是约束在任何条件下都必要。

第三，共享头带来明显的校准代价，而温度缩放不能缓解。多任务臂的平均分病种误差是单任务臂的四到六倍，六个臂在经过温度缩放后误差全部上升。判别增益与校准代价是两个独立轴，一个指标盖不住另一个。

第四，这一代价可以追溯到 logit 中心与终点流行率之间的位置差。四个多任务臂的相关系数为 0.813 至 0.864，斜率接近 1。用验证集患病率做一次零参数平移，误差从 0.122 至 0.149 降到 0.036 至 0.050。这条校正不能套到单任务臂上，那里反而会把误差推高，说明它针对的是一个具体机制，通用后处理技巧解释不了这一现象。

第五，质量条件骨干路由提高了判别，却让工作点最不稳定。E5 的事后阈值灵敏度最高，冻结后最低，落差 0.226，是六个臂中最大的。这一点在只看宏平均 AUROC 或只看一个工作点时都看不出来。

### 5.2 与已有工作的关系

Reti-Pioneer 报告质量感知模块带来 2 型糖尿病 AUROC 的提升，并给出统计检验的 P 值。本文在糖尿病视网膜病变上得到方向一致但幅度更小、区间跨零的结果。差异有三个可能来源。

其一是数据规模。原文使用 107 730 张图像，本文测试集 640 张。用区间宽度反推，若要在 80% 把握度下检出 0.002 量级的差异，测试集需扩大一个数量级以上。其二是质量标签的来源。原文使用训练好的质量模块，本文使用锐度与曝光代理量。代理量与真实质量的一致性不足，会稀释质量路由本应带来的差异。其三是权重学习的结果。表 17 显示单调路由器停在初始化附近，这本身说明在本次训练预算与数据规模下，质量权重的可学习空间没有被充分利用。原文的模块结构不同，可能更容易产生有实质偏离的解。

前人的一项研究把劣质图像进一步分成病变相关与伪影相关两类，这个区分对本文有直接含义。本文的质量代理量只看锐度与曝光，对病变相关的劣质几乎没有分辨力。玻璃膜疣与视盘杯盘比异常这两个终点恰恰依赖纤细边界，它们的低 AUROC 可能部分来自这一混淆。把质量分类器换成区分这两类的版本，是本文之后最值得做的一步。

一项列入本文参考文献的研究提醒，单中心 AUROC 在相机与标签体系漂移时容易高估可迁移性[5]。本文的结果支持这一提醒的一个具体版本。同一批图像上，宏平均 AUROC 会因为终点集合不同而在 0.896 至 0.934 之间变化，读者只看一个数字很容易误判系统能力。工作点上的情形更明显，同一个臂在同一个测试集上可以报告 0.766，也可以报告 0.540，差别只在于阈值从哪里来。

校准综述给出的位置与斜率二分框架正好容纳本文的结果[13]。多任务臂的斜率接近 1，位置偏差很大，属于位置型误校准。这类误校准的正确处理方式是按端点对齐中心，调整整体锐度解决不了位置偏差。本文给出的零参数平移是这一原则的最小实现。

### 5.3 校准误差为什么表现为 logit 偏移

多任务臂校准变差，有一个结构性解释。共享头的最后一层是八个独立线性映射，但它们共享同一组融合特征。当八个终点的患病率相差一个数量级时，融合特征会被高患病率终点主导，低患病率终点的 logit 尺度随之偏移。单一温度无法同时校正八种偏移。

第 4.6 与 4.7 节把这一推断推进了一步。原本以为温度缩放能缓解一部分，实测发现它连一部分都做不到。四个多任务臂的斜率在 0.82 至 1.02 之间，说明分数没有被整体压扁，问题在中心位置。改用 640 张验证图像拟合温度，E5 的误差从 0.122 变成 0.124。按终点分别拟合，E5 从 0.122 变成 0.124。直接在测试标签上拟合每个终点的温度，E5 从 0.122 降到 0.117，增益 0.005。三个对照都指向同一结论，误差不来自标量尺度。

至于为什么共享头会让中心偏离流行率，一个可能的机制是损失的归一化方式。式 (4) 把每个样本的损失按其观察数归一化，八个终点的损失在同一尺度上相加。当八个终点的患病率相差一个数量级时，高患病率终点在总损失里的权重更大，共享特征的更新方向被它主导，低患病率终点的头只能在一个偏向高患病率终点的特征上拟合自己的截距。这一解释与表 11 的缺口结构相符，玻璃膜疣的缺口为正，近视性改变的缺口为负，方向取决于该终点相对其余终点的患病率位置。

这一解释只有间接支持。要直接验证，需要固定共享特征、只改变各终点的损失权重，看缺口是否随之变化。本文没有做这个实验，因此只能把它写成一种与数据一致的机制，不是已经确立的因果。

### 5.4 阈值搬移的两种读法

第 4.8 节的结果值得单独讨论，因为它是本文最容易被误读的部分。

同一批测试图像上，E5 在 95% 特异度下的灵敏度可以是 0.766，也可以是 0.540，取决于阈值从哪里来。前者在测试集上挑选，后者在验证集上确定。两个数字都真实，含义完全不同。前者回答这个模型在该工作点上最多能做到多好，后者回答把它搬到新数据上会遇到什么。

两者相差 0.226，这个落差本身是有信息的。它衡量分数分布在两个集合之间的不一致程度。E5 的落差最大，说明它的分数分布对样本构成最敏感。这一点在训练时看不出来，在宏平均 AUROC 上也看不出来，只有把阈值固定住才会暴露。

这一现象对小样本评价有普遍含义。六个实验的验证集是 576 张，测试集 640 张，都是小样本。在小样本上，任何依赖固定分位数的规则都会因为分母抖动而漂移。报告单一工作点时，不说明阈值来源，读者无法判断这个数字是模型能力还是抽样偶然。因此表 14 把验证集与测试集两侧的数字都列出，并单独给出事后上界。

需要说明一处协议选择。早期版本的阈值是在测试集上直接拟合的，原因是分析脚本只读取了缓存的测试预测，没有把验证集的逐轮预测纳入。那样得到的灵敏度反映的是事后挑选的上界，不是可部署规则的表现。本文改为在验证集上确定阈值，并在表 14 中同时给出两个口径。

### 5.5 质量分层的解释边界

第 4.11 节的结果容易被误读为模型在差图像上更准。前文已说明这与患病率差异有关。这里补充一层方法学含义。

AUROC 是排序指标，对类别比例不敏感，但在阳性样本很少时，其估计方差显著增大。差层 85 张图像中糖尿病视网膜病变阳性约 7 例，任何排序波动都会带来较大的 AUROC 变化。把这一层的数值当作稳定结论并不合适。

更有信息量的做法是在同一层内比较不同臂。差层上 E5 的 0.953 与 E2 的 0.935 相差 0.018，与总体宏平均的差值方向一致。这提示路由的作用不局限于某一质量层，但也仅此而已，样本量不足以支撑更强的结论。要真正检验路由是否改善劣质图像上的表现，需要在同一批图像上比较启用与不启用路由的结果。本文用推理期钳制做了这件事，结果是概率变化不超过 0.036，见第 4.12 节。

### 5.6 局限

本文有七处局限，按重要性排列。

第一，骨干是 ImageNet 替代模型。RETFound 与 Vision Mamba 的权重在起草环境不可得，因此绝对性能不能与 Reti-Pioneer 的报道比较。所有结论都是关于部件相对表现的，不是关于基础模型能力的。

第二，只有单一随机种子。六个臂各训练一次，配对区间反映的是测试集抽样不确定性，不包含训练随机性。表 17 显示路由器停在初始化附近，这提示单次训练的随机波动可能不小。要分离训练方差，需要每个臂至少三个种子。

第三，掩码损失在本次数据上没有发挥作用。RFMiD 的八个终点全部有标注，掩码不改变损失数值。它作为跨队列兼容性的设计保留在代码中，但本文无法提供它在部分标签场景下的实验证据。

第四，质量向量来自像素代理量，不是训练好的质量分类器。这限制了质量分层结论的外推，也削弱了与前人质量感知工作的可比性。前文引用的一项研究区分病变相关与伪影相关的劣质[8]，本文的代理量没有这一分辨力。

第五，报告轮次按验证集选择，六个臂各自选择。这给每个臂一次挑选有利轮次的机会，与固定轮次比较并不严格等价。早期固定第 9 轮的结果为 E0 0.925、E1 0.931、E2 0.886、E3 0.898、E5 0.901，两组结果的方向一致，幅度不同。这一处改动在表 3 中已经公开，读者可以据此判断影响。

第六，验证集与测试集各约 600 张，工作点估计的方差偏大。E5 的阈值从验证集搬到测试集后灵敏度下降 0.226，其中相当一部分来自验证集上 95% 分位数的抖动，不完全是分数分布的真实偏移。要把两者分开，需要更大的留出集合或交叉拟合的工作点估计。本文没有做，因此第 5.4 节的解释应当读作两种因素的上界估计。

第七，E5 的骨干路由在推理期近似一个常数混合，这是本文最重要的机制发现，也带来一个需要正视的后果。表 18 显示，把该模块替换成均匀混合几乎不改变输出，说明它没有学到随图像变化的质量依赖。质量条件这一设计名义上成立，实际未被模型使用。本文因此不能声称质量条件骨干路由有效，只能说多加一层参数在这个训练配置下带来了 0.010 的增益。要让质量条件真正生效，需要更强的监督信号，例如把质量标签的辅助损失权重调高，或在训练中限制混合权重偏离均匀的程度。

### 5.7 实践含义

在上述边界内，本文给出四条可操作的判断。

若要在公开多病眼底数据上使用质量融合，优先选择有顺序约束的可学习路由。它在本次实验中不劣于固定权重，去掉约束后表现下降，说明约束提供了一个稳定的归纳偏置。同时应当意识到，学习到的权重可能停在初始化附近，增益主要来自训练

轨迹，权重本身的偏离贡献很小。因此评估这类模块时，推理期钳制实验比查看权重数值更有信息量。

若终点集合包含低患病率项目，共享头是可行的，但必须单独报告校准，并把八个终点的误差逐个列出，一个汇总数盖不住分终点的差异。温度缩放不足以修正共享头带来的误差，原因在于误差出在位置上，分数的锐度本身是合适的。按端点对齐 logit 中心的校正只需要验证集患病率，实现成本很低，值得作为默认的校准步骤。它在单任务模型上会过度校正，因此是否启用应当由端点数决定。

若筛查场景要求高特异度，必须在目标人群的留出数据上重新标定阈值，并报告阈值搬移的敏感区间。本文的 E5 在事后阈值下灵敏度最高，在冻结阈值下反而最低，两个数字相差 0.226。只报告其中一个都会误导读者。

若把 PPV 与漏诊数当作决策依据，本文的排序与 AUROC 的排序并不一致。E5 的 PPV 最高但漏诊最多，E0 在两者之间最平衡。选择哪个臂取决于漏诊与转诊的相对代价，这个权重由筛查项目决定，不能由模型指标代替。

## 6 结论

本文在 RFMiD 真实眼底像素与 ImageNet 替代骨干上，检验了视网膜多病种筛查框架中三处可替换部件的效果。主要结论如下。

1. 在八终点共享头设置下，单调质量路由相对固定权重带来 +0.010 的宏平均 AUROC 差值，95% 区间下限贴近零，逐一剔除任一终点后符号不变。在单任务设置下同类差值为 +0.001，区间跨零。前者的证据强度为边界，后者无法与零区分。

2. 用无约束自由线性路由替换单调路由后，宏平均 AUROC 下降 0.008，93% 的重采样显示下降，剔除任一终点后仍为负。推理期把权重强制改回固定值只改变 $1.9\times10^{-5}$ 的 AUROC，说明这一差异来自训练轨迹的扰动幅度，不来自学到的新权重。

3. 质量条件骨干路由把宏平均 AUROC 从 0.906 提到 0.916，Brier 从 0.101 降到 0.087，但它在 95% 特异度工作点上的可部署表现最差。冻结阈值下灵敏度

0.540，低于 E0 的 0.661。事后阈值下 0.766，高于所有其他臂。两者相差 0.226，说明该臂的分数分布对样本构成最敏感。

4. 共享多标签头带来明显的校准代价。平均分病种期望校准误差从单任务臂的 0.024 至 0.031 升到多任务臂的 0.122 至 0.149。温度缩放无法缩小这一差距，六个臂缩放后的误差全部上升。误差的性质是 logit 中心偏离终点流行率，四个多任务臂的相关系数为 0.813 至 0.864，斜率接近 1。用验证集患病率做一次零参数平移，误差降到 0.036 至 0.050。

5. 上述结论限于 RFMiD 标签体系、ImageNet 替代骨干与单一随机种子。跨队列迁移、真实基础模型权重与多种子稳定性需要在具备相应数据与算力的条件下另行检验。

## 7 数据与代码可用性

RFMiD 可按其原始数据描述论文的许可获取。BRSET 与 ODIR-5K 为公开数据集，本文未使用其图像，仅在讨论中作为标签词表差异的例子引用。

本文的代码、配置、统计脚本与图表代码位于公开仓库 https://github.com/Coucou2016/retinal-imaging-methods-public。仓库中包含特征出处记录、划分文件、逐臂指标与六组实验的检查点。全部结果可由以下命令重建。

```
python scripts/build_real_rfmid_cache.py --cache-dir data/rfmid --batch-size 8
python scripts/run_real_rfmid_experiments.py --data-dir data/rfmid --epochs 15
python scripts/select_epochs.py --runs ...
python scripts/collect_arm_predictions.py --arms ...
python scripts/collect_cal_predictions.py --arms E0 E1 E2 E3 E4 E5
python scripts/analyze_arms.py --arms E0 E1 E2 E3 E4 E5
python scripts/recalibrate_arms.py
python scripts/temperature_schemes.py
python scripts/calibration_offset_test.py
python scripts/logit_offset_analysis.py
python scripts/router_intervention.py
python scripts/clinical_utility.py
python scripts/operating_point_analysis.py
python scripts/threshold_transfer.py
python scripts/endpoint_robustness.py
python scripts/export_manuscript_numbers.py
python scripts/plot_manuscript_figures.py
python scripts/plot_analysis_figures.py
python scripts/plot_recalibration_figures.py
```

```
python scripts/plot_extra_figures.py
python scripts/plot_router_figure.py
```

特征出处记录在 `data/rfmid/FEATURE_PROVENANCE.json`，其中写明三个骨干的实际权重来源与替代原因。本文不包含任何患者可识别信息，使用的眼底图像均为公开数据集内容。

## 参考文献


1. Zhou Y, Chia MA, Wagner SK, et al. A foundation model for generalizable disease detection from retinal images. *Nature*. 2023;622:156-163. doi:10.1038/s41586-023-06555-x

2. Zhang X, Li Q, Liang Y, et al. AI framework for multidisease detection via retinal imaging. *Nature Medicine*. 2026;32:2494-2503. doi:10.1038/s41591-026-04359-w

3. Reti-Pioneer reference implementation. GitHub repository. https://github.com/lyhyl/Reti-Pioneer

4. Müller D, Soto-Rey I, Kramer F. Multi-disease detection in retinal imaging based on ensembling heterogeneous deep learning models. *Studies in Health Technology and Informatics*. 2021;281:199-203. doi:10.3233/SHTI210537

5. Matta S, Lamard M, Conze PH, et al. Towards population-independent, multi-disease detection in fundus photographs. *Scientific Reports*. 2023;13:11493. doi:10.1038/s41598-023-38610-y

6. Fu H, Wang B, Shen J, et al. Evaluation of retinal image quality assessment networks in different color-spaces. In: *Medical Image Computing and Computer Assisted Intervention*. 2019:48-56. doi:10.1007/978-3-030-32239-7_6

7. Huang C, Jiang Y, Yang X, et al. Enhancing retinal fundus image quality assessment with Swin-Transformer-based learning across multiple color-spaces. *Translational Vision Science & Technology*. 2024;13:8. doi:10.1167/tvst.13.4.8

8. Shi C, Lee J, Wang G, et al. Assessment of image quality on color fundus retinal images using the automatic retinal image analysis. *Scientific Reports*. 2022;12:10455. doi:10.1038/s41598-022-13919-2

9. Pachade S, Porwal P, Thulkar D, et al. Retinal Fundus Multi-Disease Image Dataset (RFMiD): a dataset for multi-disease detection research. *Data*. 2021;6:14. doi:10.3390/data6020014

10. Nakayama LF, Restrepo D, Matos J, et al. BRSET: a Brazilian multilabel ophthalmological dataset of retina fundus photos. *PLOS Digital Health*. 2024;3:e0000454. doi:10.1371/journal.pdig.0000454

11. ODIR-5K Grand Challenge dataset documentation. https://odir2019.grand-challenge.org/dataset/

12. Guo C, Pleiss G, Sun Y, Weinberger KQ. On calibration of modern neural networks. In: *International Conference on Machine Learning*. 2017:1321-1330. doi:10.48550/arXiv.1706.04599

13. Van Calster B, McLernon DJ, van Smeden M, et al. Calibration: the Achilles heel of predictive analytics. *BMC Medicine*. 2019;17:230. doi:10.1186/s12916-019-1466-7

14. Naeini MP, Cooper GF, Hauskrecht M. Obtaining well calibrated probabilities using Bayesian binning. In: *Proceedings of the AAAI Conference on Artificial Intelligence*. 2015;29:2901-2907. doi:10.1609/aaai.v29i1.9602

15. Platt J. Probabilities for SV machines. In: Smola AJ, Bartlett P, Schölkopf B, Schuurmans D, eds. *Advances in Large-Margin Classifiers*. Cambridge: MIT Press; 2000:61-74. doi:10.7551/mitpress/1113.003.0008

16. Zadrozny B, Elkan C. Transforming classifier scores into accurate multiclass probability estimates. In: *Proceedings of the Eighth ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2002:694-699. doi:10.1145/775047.775151

17. Vickers AJ, Elkin EB. Decision curve analysis: a novel method for evaluating prediction models. *Medical Decision Making*. 2006;26:565-574. doi:10.1177/0272989X06295361

18. Zhang J, Mao B, Wang X, et al. RETFound-enhanced community-based fundus disease screening: real-world evidence and decision curve analysis. *npj Digital Medicine*. 2024;7:108. doi:10.1038/s41746-024-01109-5

19. Collins GS, Moons KGM, Dhiman P, et al. TRIPOD+AI statement: updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*. 2024;385:e078378. doi:10.1136/bmj-2023-078378

20. Brier GW. Verification of forecasts expressed in terms of probability. *Monthly Weather Review*. 1950;78:1-3. doi:10.1175/1520-0493(1950)078<0001:VOFEIT>2.0.CO;2

21. Youden WJ. Index for rating diagnostic tests. *Cancer*. 1950;3:32-35. doi:10.1002/1097-0142(1950)3:1<32::AID-CNCR2820030106>3.0.CO;2-3

22. Efron B, Tibshirani RJ. *An Introduction to the Bootstrap*. New York: Chapman and Hall; 1993. doi:10.1201/9780429246593

23. DeLong ER, DeLong DM, Clarke-Pearson DL. Comparing the areas under two or more correlated receiver operating characteristic curves: a nonparametric approach. *Biometrics*. 1988;44:837-845. doi:10.2307/2531595

24. Niculescu-Mizil A, Caruana R. Predicting good probabilities with supervised learning. In: *Proceedings of the 22nd International Conference on Machine Learning*. 2005:625-632. doi:10.1145/1102351.1102430